



En respuesta a Primera publicación

Re: Foro semana 5

de [Sandra Vargas](#) - martes, 29 de septiembre de 2026, 00:27

Caso 3: Clasificación de piezas aceptables/defectuosas

Comparación de modelos: primero aplicaría KNN, porque el problema presenta varios grupos de piezas aceptables con diferentes combinaciones de peso y tamaño. KNN puede manejar naturalmente estas relaciones sin asumir una forma específica. Sin embargo, es sensible al ruido y a la escala de las variables, por lo que algunos vecinos podrían pertenecer a la clase equivocada. Luego utilizaría un árbol de decisión, que permite establecer reglas interpretables, sería útil si control de calidad quiere reglas del tipo "si peso > X y vibración > Y, entonces defectuosa", pero con un dataset de solo 6.000 registros y ruido en las mediciones, un árbol sin restricción de profundidad aprendería los casos específicos y sobreajustaría. Finalmente aplicaría Regresión Logística, sería la más simple de mantener en producción, pero su límite de decisión lineal probablemente falle frente a "grupos" de piezas aceptables con combinaciones distintas, salvo que se agreguen interacciones o transformaciones, que el enunciado da a entender que no están presentes.

Características del dataset: dos características relevantes son el ruido en las mediciones y valores muy parecidos entre clases, lo cual perjudica especialmente a K-NN con K muy pequeño, porque vecinos ruidosos pueden inducir errores. También puede afectar a la regresión logística si intenta separar con una frontera lineal. Los árboles pueden aislar algunos ruidos si se podan, pero si crecen demasiado los memorizan.

Preparación de los datos: escalaría las variables numéricas (peso, longitud, diámetro, temperatura y vibración), especialmente para K-NN, ya que las variables con mayor escala podrían dominar el cálculo de distancias. Para el tipo de material utilizaría one-hot encoding, evitando asignar valores como 1, 2 y 3, porque introducirían un orden y una distancia que no existen entre categorías. Sobreajuste y subajuste: en KNN, un K muy pequeño puede ser demasiado sensible al ruido, mientras que uno muy grande puede mezclar grupos diferentes. Un árbol muy profundo puede memorizar los datos y sobreajustar, mientras que uno demasiado limitado puede generar subajuste. En Regresión Logística, una regularización excesiva puede provocar subajuste y una insuficiente puede favorecer el sobreajuste.

Evaluación: definiría "defectuosa" como clase positiva y priorizaría el recall, porque un falso negativo significa clasificar una pieza defectuosa como aceptable y permitir que llegue al cliente. La accuracy por sí sola podría ocultar este problema. En general, el falso negativo suele tener mayor costo, porque puede afectar la seguridad o la reputación.

Comparación justa: separaría los datos en entrenamiento, validación y prueba antes de realizar el escalado o ajuste. Los tres modelos deberían evaluarse sobre el mismo conjunto de prueba. KNN y Regresión Logística requieren escalado, mientras que el árbol de decisión no.

Pregunta abierta: si aparecieran nuevos tipos de material no vistos en el entrenamiento, ¿cómo afectaría esto a cada uno de los tres modelos?



En respuesta a Sandra Vargas

Re: Foro semana 5

de [Ariel Tuñon](#) - miércoles, 30 de septiembre de 2026, 11:34

Hola Sandra!

Me pareció interesante la intención de comenzar primero con el método de KN-N porque si nos preguntamos ¿podría ser útil clasificar una pieza según sus vecinas más cercanas? Podemos decir que KN-N puede adaptarse a diferentes grupos de piezas según sus mediciones, aunque previamente habría que escalar las variables y tener en cuenta como bien decís, su sensibilidad al ruido porque vecinos ruidosos pueden inducir errores. Por eso, también consideraría probar un árbol de decisión o Random Forest y comparar su desempeño mediante validación cruzada, prestando especial atención al recall de la clase "defectuosa". ya que sería importante reducir el riesgo de clasificar una pieza defectuosa como aceptable. Finalmente, si estas probando modelos puedo sugerir observar los valores con una matriz de confusión y también comparar los valores de métricas como accuracy, precision, recall y F1-score para determinar cuál se adapta mejor a los datos.

Saludos!



En respuesta a Ariel Tuñon


Re: Foro semana 5

de [Sandra Vargas](#) - domingo, 4 de octubre de 2026, 22:18

Hola Ariel, estoy de acuerdo en que no es suficiente elegir un único modelo, es importante comparar distintas alternativas y también usar validación cruzada. También

me parece importante lo que mencionás sobre la matriz de confusión, porque en este caso nos permite observar específicamente cuántas piezas defectuosas fueron clasificadas incorrectamente como aceptables.

Gracias por tu aporte. .Saludos!



En respuesta a Sandra Vargas

Re: Foro semana 5

de [Mauricio Turdo](#) - jueves, 1 de octubre de 2026, 15:02

Hola Sandra, Muy claro tu análisis del Caso 3. Coincido totalmente en que la prioridad tiene que ser el Recall para no mandarle ninguna pieza defectuosa al cliente.

Lo que sí me parece interesante de analizar es la idea de empezar con K-NN, ya que este modelo asume que las mediciones de las máquinas vienen limpias y que las piezas parecidas se agrupan juntas. Pero como en la fábrica hay ruido en los sensores y piezas buenas mezcladas con malas, ese supuesto no se cumple: un solo dato ruidoso (un sensor que midió mal) puede engañar a K-NN y hacer que clasifique mal a las piezas sanas de alrededor.

Por eso, creo que lo más conveniente es empezar con un Árbol de Decisión limitado, que tolera mucho mejor esos fallos aislados.



En respuesta a Sandra Vargas

Re: Foro semana 5

de [Monica Maria Frias](#) - sábado, 3 de octubre de 2026, 13:43

Hola Sandra, me pareció muy acertado empezar con KNN por los distintos grupos de piezas aceptables. Me puse a pensar qué pasaría si la fábrica agregara muchos sensores nuevos y la mayoría no tuviera relación con los defectos. Creo que ahí KNN se vería bastante afectado, porque usa todas las variables por igual para calcular las distancias, y las que no aportan nada terminarían metiendo ruido. Es lo que en la clase llamamos la maldición de la dimensionalidad. En ese escenario yo empezaría por el árbol de decisión, que en cada división elige la variable más útil y además nos muestra cuáles fueron las más importantes. Con esa información me quedaría solo con las variables relevantes y después sí aplicaría KNN.



En respuesta a Sandra Vargas

Re: Foro semana 5

de [Gabriela Soledad Bacchiani](#) - domingo, 4 de octubre de 2026, 20:26

Hola Sandra! tu justificación de empezar con K-NN es sólida para 6.000 registros. Quisiera plantear qué pasaría si la cantidad de registros creciera a varios millones por una línea de producción con sensores continuos. K-NN tendría que comparar cada pieza nueva con todo el conjunto de entrenamiento, y el costo de predicción en tiempo y memoria podría volverlo inviable para el control de calidad en tiempo real, algo que hemos visto como su punto débil. En ese escenario, con mucha más información, el árbol ya no sobreajustaría tanto y la regresión logística sería rápida de entrenar y de poner en producción. Por eso probablemente pasaría a un árbol con profundidad controlada como modelo principal, y conservaría K-NN solo como referencia sobre una muestra. ¿Mantendrías tu propuesta original si aumentara el volumen de datos?

Sobre tu pregunta: ningún modelo estaría preparado para un material nuevo, pero fallarían de formas distintas. Con one-hot, el material nuevo aparecería como todos ceros. En la regresión logística, la pieza se evaluaría como si no tuviera material, apoyándose solo en peso, vibración, etc., sin ningún coeficiente propio. En el árbol, caería en las ramas de "no es ninguno de los materiales conocidos" y terminaría en una hoja casi arbitraria. En K-NN, esa pieza quedaría a la misma distancia de todos los materiales conocidos, así que los vecinos dependerían solo de las variables numéricas. Podría llegar a funcionar si el material nuevo se comporta parecido a alguno conocido. Lo más riesgoso es que los tres darían una predicción sin avisar que no tienen evidencia. Por eso monitorearía la aparición de categorías nuevas, derivaría esas piezas a inspección manual y reentrenaría el modelo con ellas. ¿Vos agregarías esa alerta antes de poner el modelo en producción?



En respuesta a Gabriela Soledad Bacchiani

Re: Foro semana 5

de [Sandra Vargas](#) - domingo, 4 de octubre de 2026, 22:51

Hola Gabriela, en respuesta al cambio que planteas, al aumentar el volumen de datos a millones de registros y además trabajar predicciones en tiempo real, no elegiría KNN como modelo principal, ya que el costo de calcular las distancias con tantos registros podría ser demasiado alto. Sería conveniente un árbol de decisión, comparando su desempeño y especialmente el recall de la clase "defectuosa".

Sí, agregaría esa alerta antes de poner el modelo en producción. El sistema no sólo daría una predicción, sino que también podría detectar un material nuevo o valores de las mediciones muy diferentes de los datos utilizados durante el entrenamiento. Las piezas nuevas podrían derivarse a inspección manual y luego utilizaría esos nuevos datos para reentrenar el modelo. De esta forma se reduce el riesgo de que el sistema tome una decisión sobre una situación para la cual no tiene suficiente información. Muchas gracia spor tu aporte. Saludos.