

Aprendizaje Automático - Libro 1 - Clase 1 a 7

6. Clase 6

Clase N° 6: Aprendizaje Supervisado (III)

Contenido: Algoritmos de clasificación lineal: Support Vector Machine. Método de optimización: Stochastic Gradient Descent.

En la clase de hoy trabajaremos los siguientes temas:

- Support Vector Machine
 - Hiperplano
 - Vectores de Soporte
 - Margen
 - Hiperplano de margen máximo
 - Problema con conjuntos de datos dispersos
 - El truco del Kernel
 - Linear kernel
 - Polynomial Kernel
 - Radial Basis Function Kernel (RDF)
 - Sigmoid kernel
 - Actividad
- Stochastic Gradient Descent
 - El proceso típico del SGD

1. Presentación:

Bienvenidos a la clase N° 6 de Aprendizaje Automático.

En esta clase continuaremos desarrollando el tema de Aprendizaje Supervisado, exploraremos dos pilares fundamentales del aprendizaje automático: el algoritmo de clasificación lineal Support Vector Machine (SVM) y el método de optimización Stochastic Gradient Descent (SGD). Con respecto a SVM, se aplica en la clasificación de correos electrónicos como spam o no spam hasta la identificación de fraudes en transacciones financieras, SVM se ha destacado por su capacidad para separar eficazmente conjuntos de datos complejos mediante hiperplanos. Además, SVM puede ser empleado en la detección de enfermedades médicas a partir de imágenes o en la categorización de documentos según su contenido. Por otro lado, exploraremos el poderoso método de optimización SGD, que desempeña un papel esencial en el entrenamiento de modelos de aprendizaje automático, desde redes neuronales hasta regresiones lineales. El SGD se utiliza en la convergencia de modelos de aprendizaje profundo, en la optimización de funciones de costo y en aplicaciones como el entrenamiento de sistemas de recomendación y la personalización de contenido en plataformas de streaming. A lo largo de esta clase, descubriremos cómo estos dos elementos clave impulsan el aprendizaje supervisado y su aplicación en una amplia variedad de escenarios del mundo real.

2. Desarrollo y Actividades:

Los conceptos que estudiaremos en esta clase se relacionan con lo que vimos anteriormente en las clases anteriores en referencia al Aprendizaje Supervisado.

Si no recuerdas estos temas te invitamos a que revises nuevamente la clase N° 5 y clase N° 4. Si te quedan dudas sobre este tema siempre podés consultar en el foro o en las tutorías cuando nos encontremos.

CLASIFICADORES LINEALES

Support Vector Machine

Las *Máquinas de Soporte Vectorial* (SVM, por sus siglas en inglés) son algoritmos de aprendizaje automático que se utilizan para fines de clasificación y regresión. Son considerados como uno de los algoritmos de aprendizaje automático más poderosos para propósitos de *clasificación, regresión y detección de valores atípicos*. Un modelo de clasificador SVM es construido, a su vez, por nuevos puntos de datos para ser asignados a una de las categorías dadas. Por consiguiente, puede ser visto como un clasificador binario lineal *no probabilístico*.

Los SVMs pueden ser utilizados para fines de *clasificación lineal*. Además de la realización de la clasificación lineal, una clasificación *no lineal* puede ser eficientemente realizada por las SVMs utilizando *el truco del kernel*. Esto permite que las entradas sean mapeadas implícitamente en espacios de características de alta dimensión.

Su popularidad radica en su capacidad para generar modelos de alta precisión y eficacia en la toma de decisiones. Aquí, presentaremos algunos términos relacionados con las SVM:

Hiperplano

Un hiperplano es una frontera de decisión que separa un conjunto dado de puntos de datos que tienen diferentes etiquetas de clase. Los puntos de datos son separados por el clasificador SVM utilizando un hiperplano con la máxima cantidad de margen. Este hiperplano se conoce como el *hiperplano de margen máximo* y el clasificador lineal que es definido por él se conoce como el *clasificador de margen máximo*.


Vectores de Soporte

Los puntos de datos de muestra que están más cerca del hiperplano son conocidos como vectores de soporte. Estos puntos de datos son los que mejor definen la línea o hiperplano de separación al calcular los márgenes.

Margen

Un margen es un espacio de separación entre las dos líneas en los puntos de datos más cercanos. Se calcula como la distancia perpendicular desde la línea hasta los vectores de soporte o los puntos de datos más cercanos. En las SVM, se intenta maximizar este espacio de separación para obtener el margen máximo.

El siguiente diagrama ilustra estos conceptos.




Hiperplano de margen máximo

En las SVM, nuestro objetivo principal es seleccionar un *hiperplano con el margen máximo* posible entre los vectores de soporte en el conjunto de datos dado. El hiperplano de margen máximo es buscado por las SVM en el siguiente proceso de 2 pasos:


1. Se generan hiperplanos que segregan las clases de la mejor manera posible. Hay muchos hiperplanos que podrían clasificar los datos. El mejor hiperplano que representa la mayor separación, o margen, entre las dos clases, debe ser buscado.
2. Entonces, se elige el hiperplano de manera que se maximice la distancia desde él hasta los vectores de soporte en cada lado. Si existe tal hiperplano, se conoce como el *hiperplano de margen máximo* y el clasificador lineal que es definido por él se conoce como un *clasificador de margen máximo*.

El siguiente diagrama ilustra de manera clara el concepto de *margen máximo* y *hiperplano de margen máximo*.



Problema con conjuntos de datos dispersos

A veces, los puntos de datos de muestra están tan dispersos que no es posible separarlos utilizando un hiperplano lineal. En tales situaciones, se utiliza un *truco de kernel* en las SVM para transformar el espacio de entrada a un espacio de dimensiones superiores, como se muestra en el diagrama a continuación. Se emplea una función de mapeo para transformar el espacio de entrada de 2 dimensiones a un espacio de entrada de 3 dimensiones. Ahora, los puntos de datos pueden ser fácilmente segregados utilizando una separación lineal.



El truco del Kernel

En la práctica, el algoritmo SVM es implementado utilizando un *kernel*. Se utiliza una técnica llamada *truco del kernel*. En palabras sencillas, un kernel es simplemente una función que mapea los datos a una dimensión superior donde los datos son separables. Un kernel transforma un espacio de datos de entrada de baja dimensión en un espacio de dimensión superior. De esta manera, convierte problemas no lineales separables en problemas linealmente separables al agregar más dimensiones. Así, el *truco del kernel* nos ayuda a construir un clasificador más preciso. Por lo tanto, es útil en problemas de separación no lineal.

En el contexto de las SVM, existen 4 núcleos populares:

Linear kernel

El *kernel lineal* es utilizado cuando los datos son separables de manera lineal. Esto significa que los datos pueden ser separados mediante una única línea. Es uno de los kernels más comunes que se utilizan. Se emplea principalmente cuando existe un gran número de características en un conjunto de datos. El kernel lineal es frecuentemente utilizado con fines de clasificación de texto. El entrenamiento con un kernel lineal suele ser más rápido, porque solo necesitamos optimizar el *parámetro de regularización C*.

Polynomial Kernel

El *kernel* polinómico representa la similitud de los vectores (muestras de entrenamiento) en un espacio de características a través de polinomios de las variables originales. El kernel polinómico no solo mira las características dadas de las muestras de entrada para determinar su similitud, sino también combinaciones de las muestras de entrada. El kernel polinómico es muy popular en el procesamiento del lenguaje natural.

Radial Basis Function Kernel (RBF)

El kernel de función de base radial es un kernel de propósito general. Se utiliza cuando no se tiene conocimiento previo sobre los datos.

Sigmoid kernel

El kernel sigmoide tiene su origen en las redes neuronales. Puede ser utilizado como sustituto de las redes neuronales.

Actividad

Es importante que realices todas las actividades, estas te permitirán saber como vas avanzando y podrás reflexionar sobre la teoría si te queda alguna duda de cómo hacer esta actividad por favor consultanos en el campus.

Deberás abrir la notebook que se encuentra en el repositorio de la materia para poder realizar la actividad de SVM utilizando la librería Scikit-Learn.

Scikit-Learn ofrece un conjunto de módulos útiles para implementar el algoritmo de Máquina de Soporte Vectorial en un conjunto de datos. Simplemente debemos llamar a la biblioteca con los parámetros que se adapten a nuestras necesidades. En esta notebook, estamos tratando con una tarea de clasificación. Por lo tanto, mencionaré las bibliotecas de Scikit-Learn para fines de clasificación mediante SVM.

MÉTODO DE OPTIMIZACIÓN

Stochastic Gradient Descent

En el ámbito del Aprendizaje Automático, los métodos de optimización desempeñan un papel fundamental. Estos métodos se utilizan para *ajustar los parámetros* de un modelo de aprendizaje automático con el fin de *minimizar una función de costo*, lo que permite que el modelo aprenda de los datos de manera efectiva y haga predicciones precisas. La utilidad principal de los métodos de optimización radica en encontrar los valores óptimos de los parámetros del modelo para que este pueda generalizar adecuadamente a nuevos datos, lo que se traduce en un mejor rendimiento predictivo.

Uno de los métodos de optimización más ampliamente utilizados en Aprendizaje Automático es el "Stochastic Gradient Descent" o "Descenso de Gradiente Estocástico" (SGD). Este método se destaca por su eficiencia y capacidad para manejar grandes conjuntos de datos. A continuación, se describe brevemente cómo funciona el SGD:

El SGD es una variante del método de descenso de gradiente convencional. En lugar de calcular el gradiente de la función de costo utilizando todos los ejemplos de entrenamiento a la vez, el SGD utiliza solo un ejemplo de entrenamiento aleatorio en cada iteración. Esto introduce aleatoriedad en el proceso de optimización, lo que puede ser beneficioso para escapar de los *mínimos locales* y converger más rápido hacia un *mínimo global*.

En el contexto de la optimización de funciones de costo, los *mínimos locales* son puntos dentro de una región local del espacio de parámetros donde una función de costo alcanza un valor mínimo relativo en lugar de un *mínimo global*, que es el valor más bajo en todo el dominio. Estos *mínimos locales* son puntos donde la pendiente (gradiente) de la función de costo es igual a cero, lo que significa que no hay una dirección en la que se pueda mejorar aún más el valor de la función de costo moviéndose localmente.

El desafío en la optimización de modelos de Aprendizaje Automático es evitar quedarse atrapado en mínimos locales, ya que esto podría llevar a soluciones subóptimas. Los métodos de optimización, como el Descenso de Gradiente Estocástico (SGD), a menudo introducen aleatoriedad en el proceso para ayudar a escapar de los mínimos locales y, en última instancia, converger hacia un mínimo global o una solución cercana al óptimo.

El proceso típico del SGD

Este proceso consta de tres pasos:

1. Se selecciona aleatoriamente un ejemplo de entrenamiento del conjunto de datos.
2. Se calcula el gradiente de la función de costo con respecto a los parámetros del modelo utilizando ese ejemplo único.

3. Se actualizan los parámetros del modelo en la dirección opuesta al gradiente calculado, multiplicado por una tasa de aprendizaje (que controla el tamaño de los pasos de actualización).

Este proceso se repite muchas veces (a menudo miles o millones de iteraciones) hasta que la función de costo converge o se detiene según algún criterio de parada predefinido.

El SGD es especialmente valioso cuando se trabaja con grandes conjuntos de datos, ya que reduce significativamente el tiempo de entrenamiento en comparación con el descenso de gradiente tradicional, que requeriría calcular el gradiente en todos los datos de entrenamiento en cada iteración. Sin embargo, debido a su aleatoriedad inherente, el SGD puede mostrar una convergencia más ruidosa en comparación con otros métodos de optimización más deterministas, como el descenso de gradiente por lotes. Por lo tanto, la elección del método de optimización depende de las características del problema y los recursos disponibles..

3. Instancia de evaluación: Entrega de presentación grabada

En esta clase de aprendizaje supervisado abordamos el tema de Support Vector Machine (SVM), junto con la función del Gradiente Estocástico Descendiente (SGD) utilizando la librería scikit-learn, la cual nos permite probar el resultado de diferentes clasificadores lineales fácilmente. Junto con los modelos que vimos las semanas anteriores tenemos un panorama de varios modelos de clasificación que podemos utilizar.

Consigna: deberás elegir 2 modelos de clasificación de los vistos en el bloque y utilizando un dataset de tu interés aplicar ambos modelos para resolver un problema de aprendizaje automático. Deberás entregar la notebook en tu repositorio y además un video de no más de 5/7 minutos donde expliques cómo cada modelo elegido resuelve el problema, qué evaluación podemos hacer de cada modelo y en conclusión cuál modelo considerarás que aborda mejor el problema. El dataset debe tener al menos 5 variables predictoras, debe haber variables numéricas y categóricas, puede ser un caso de clasificación binaria o multinomial. No podés repetir un dataset que se haya mostrado en clase o que ya hayas utilizado en actividades anteriores.

Criterios de evaluación:

- Entregar en tiempo y forma
- Realizar un 60% de la actividad correctamente.
- Cumplir con las consignas
- Cumplir con el formato requerido.

4. Cierre:

En conclusión, en esta clase hemos explorado dos aspectos esenciales del aprendizaje automático: el algoritmo de clasificación lineal Support Vector Machine (SVM) y el método de optimización Stochastic Gradient Descent (SGD). Hemos aprendido cómo SVM nos permite separar de manera efectiva conjuntos de datos complejos mediante hiperplanos de márgenes máximos, y cómo el truco del kernel nos permite abordar problemas de clasificación no lineal. Por otro lado, hemos entendido cómo SGD optimiza modelos de aprendizaje automático de manera eficiente, contribuyendo a la convergencia de modelos complejos. La importancia de este conocimiento radica en su aplicabilidad en una amplia gama de campos, desde la detección de spam en correos electrónicos hasta el diagnóstico médico y la toma de decisiones financieras. SVM y SGD nos brindan las herramientas necesarias para abordar problemas reales y extraer información valiosa de datos complejos, lo que hace que este conocimiento sea esencial en el mundo actual impulsado por los datos. Estos algoritmos no solo mejoran la precisión de nuestras predicciones, sino que también nos ayudan a tomar decisiones más fundamentadas y eficaces en una variedad de escenarios.

Te esperamos en los próximos encuentros. Recordá que es importante participar de los foros, de los encuentros sincrónicos y en lo posible de las tutorías presenciales.

Para finalizar te dejamos estos recursos que pueden ayudarte a entender el tema un poco más.

Webografía

· "scikit-learn." *scikit-learn: machine learning in Python — scikit-learn 1.2.2 documentation*, <https://scikit-learn.org/stable/>. Accedido el 23 Junio del 2023.

5. Bibliografía Obligatoria:

- HAN, R. (2019): *Matemáticas del Aprendizaje Automático. Introducción a la analítica de datos e Inteligencia Artificial*.
- JONES, H. (2019): *Aprendizaje Automático. El Aprendizaje Automático para principiantes que desean comprender aplicaciones, Inteligencia Artificial, Minería de Datos, Big Data y más*. Editorial Edición Kindle.
- RUSSELL, R. (2018): *Machine Learning. Guía Paso a Paso Para Implementar Algoritmos De Machine Learning Con Python*
- VIDALES, A. (2019) *Machine Learning Con Matlab*. Editorial Edición Kindle.
- CANE, A. (2019): *Programación Con Python. Guía completa para principiantes*.
- HERNÁNDEZ, V. (2019): *Aprendizaje Automático. Implementación en Inteligencia Artificial*. Editorial Edición Kindle.