Aprendizaje Automático - Libro 1 - Clase 1 a 7

7. Clase 7

Clase Nº 7: Repaso y consultas.

Contenido: Repaso de la clase 1 a la clase6.

En la clase de hoy trabajaremos los siguientes temas:

Clase 1: Conceptos previos y herramientas
Clase 2: Adquisición de datos con Pandas
Clase 3: Inspección y visualización de datos
Clase 4: Aprendizaje Supervisado I – Regresión
Clase 5: Aprendizaje Supervisado II – KNN y Árboles de Decisión
Clase 6: Aprendizaje Supervisado III – SVM y SGD

1. Presentación:

Bienvenidos a la **clase N° 7** del bloque de **Aprendizaje Automático**. Esta semana nos tomaremos un tiempo para repasar, revisar y practicar todos los contenidos presentados desde la clase 1 hasta la clase 6 inclusive.

Este espacio está pensado como una oportunidad para consolidar los conocimientos adquiridos, reforzar aquellos conceptos que hayan resultado más desafiantes y afianzar las habilidades prácticas desarrolladas a lo largo del curso. Aprender a aprender también implica detenerse, reflexionar y volver sobre lo ya recorrido con una mirada más profunda y segura.

Durante estos días, tendrán la posibilidad de plantear todas las dudas o inquietudes que hayan surgido. Podrán participar en los foros, asistir a tutorías o consultar los materiales complementarios que se encuentran en el campus. Además, se habilitarán los instrumentos de evaluación correspondientes, de manera que puedan ingresar y completar las actividades pendientes o aquellas que no hayan podido realizar en su debido momento.

Se alienta a retomar la lectura de los apuntes, revisar los notebooks compartidos y, en especial, volver a mirar los videos de los encuentros sincrónicos grabados, donde se explican paso a paso los conceptos clave y se proponen ejemplos prácticos. Este recorrido de revisión no solo servirá para ponerte al día, sino también para ganar confianza y autonomía en el uso de las herramientas y técnicas que forman parte del aprendizaje automático.

Les invitamos a aprovechar esta semana como un momento valioso para reforzar lo aprendido, completar sus trayectorias y prepararse con mayor solidez para los desafíos que vendrán. Estamos para acompañarlos en este proceso.

1. Desarrollo y Contenidos:

Clase 1: Conceptos previos y herramientas

En esta clase introductoria se presentan los fundamentos esenciales del Aprendizaje Automático, una disciplina clave dentro del campo de la inteligencia artificial. El abordaje comienza aclarando que el aprendizaje automático no busca reemplazar al conocimiento humano experto, sino potenciarlo. Su utilidad se evidencia en la capacidad de analizar grandes volúmenes de datos, identificar patrones complejos y tomar decisiones de forma autónoma. Se exploran diversas áreas de aplicación, como la salud, la seguridad vial y la industria, destacando cómo algoritmos inteligentes pueden asistir en contextos críticos. A su vez, se profundiza en los conceptos de aprendizaje supervisado y no supervisado. En el primero, los algoritmos aprenden a partir de datos etiquetados, conociendo las respuestas correctas, lo cual les permite realizar predicciones precisas. En cambio, el aprendizaje no supervisado se basa en datos sin etiquetas, buscando estructuras ocultas en ellos. También se introduce el flujo de trabajo típico de un proyecto de machine learning, que incluye etapas como la formulación de una pregunta relevante, la adquisición de datos, el preprocesamiento, el modelado, la evaluación de resultados y la comunicación efectiva de conclusiones. Asimismo, se presentan los roles del equipo de trabajo en IA y las habilidades necesarias para participar activamente en un proyecto de estas características. Por último, se destacan herramientas como Python y sus librerías, que facilitan el desarrollo de soluciones de aprendizaje automático sin necesidad de programar desde cero.

Clase 2: Adquisición de datos con Pandas

La segunda clase está dedicada a la adquisición y manejo de datos, una de las tareas más relevantes en el desarrollo de modelos de aprendizaje automático. En esta instancia se trabaja con la librería Pandas, que permite importar, organizar y transformar datos provenientes de múltiples fuentes. La clase comienza con ejemplos prácticos de cómo leer archivos en formato CSV, Excel, JSON, HTML, XML y bases de datos SQLite. Se explican funciones clave como read_csv, read_excel y read_json, junto con parámetros útiles para personalizar la lectura de datos. Se destaca la importancia del DataFrame como estructura tabular fundamental en Pandas, y cómo utilizar técnicas de indexación, selección de columnas, filtrado y limpieza de filas para preparar los datos antes del modelado. También se enseña cómo integrar Pandas con otras librerías del ecosistema de Python, como NumPy y Scikit-learn, lo que facilita la transición del análisis de datos a la construcción de modelos. A través de ejemplos concretos, se evidencia que la calidad de los datos tiene un impacto directo en el rendimiento de los algoritmos. Se promueve el desarrollo de habilidades prácticas en la manipulación de datos reales, subrayando que sin una adecuada adquisición y preprocesamiento, incluso los modelos más avanzados podrían arrojar resultados erróneos o poco útiles.

Clase 3: Inspección y visualización de datos

En esta clase se profundiza en la inspección y visualización de datos utilizando la biblioteca Matplotlib. Se enfatiza que visualizar datos no es solo una cuestión estética, sino una herramienta clave para la comprensión, detección de errores, selección de características y evaluación de modelos. Se introducen distintos tipos de gráficos como líneas, dispersión, histogramas, mapas de colores y funciones polinomiales. A través de ejemplos paso a paso, se enseña a crear gráficos personalizados ajustando parámetros como color, estilo de línea, etiquetas, títulos y leyendas. Se muestran técnicas para posicionar elementos dentro del gráfico, controlar los ejes, añadir grillas y generar visualizaciones interactivas en entornos como Jupyter Notebook. Se destaca el uso de colores adecuados en mapas secuenciales, divergentes o cualitativos, según el tipo de datos que se desea representar. También se explican conceptos clave como la generación de puntos aleatorios y su uso en gráficos de dispersión o simulaciones. Además, se introduce el uso de funciones como polyfit y poly1d para ajustar curvas a través de polinomios. La clase concluye resaltando la importancia de utilizar visualizaciones efectivas no solo para el análisis, sino también para comunicar resultados a colegas, clientes o responsables de la toma de decisiones, contribuyendo a una mejor interpretación de los modelos construidos.

Clase 4: Aprendizaje Supervisado I – Regresión

La cuarta clase introduce formalmente el aprendizaje supervisado a través de dos enfoques fundamentales: la regresión lineal y la regresión logística. Se parte del concepto de que en este tipo de aprendizaje, los datos cuentan con atributos adicionales que deseamos predecir. Cuando la variable objetivo es continua, hablamos de regresión; cuando es categórica, hablamos de clasificación. Para comprender estos conceptos, se enseña a preparar conjuntos de entrenamiento y prueba, distinguiendo su utilidad dentro del ciclo de vida de un modelo. En el caso de la regresión lineal, se utiliza la librería Scikit-learn para ajustar modelos a datos reales importados mediante Pandas. Se introduce el objeto LinearRegression y su método fit, que permite ajustar los parámetros de la recta a los datos. Se evalúa el rendimiento del modelo con métricas como el error medio absoluto, el error cuadrático medio y el coeficiente de determinación R^2. Además, se presenta la regresión contraída o "ridge regression", que añade un término de penalización para reducir el impacto de valores atípicos. En la segunda parte de la clase se introduce la regresión logística como un modelo de clasificación binaria, útil por ejemplo para distinguir entre correos electrónicos spam y no spam. Se trabaja con LogisticRegression y se visualizan los resultados para comprender cómo el modelo separa las clases. Se concluye destacando que estas herramientas permiten crear modelos predictivos sólidos cuando se cuenta con datos etiquetados y adecuadamente preprocesados.

Clase 5: Aprendizaje Supervisado II – KNN y Árboles de Decisión

La clase cinco amplía los métodos de clasificación introduciendo dos algoritmos fundamentales: K-Nearest Neighbors (K-NN) y Árboles de Decisión. El algoritmo K-NN se presenta como un modelo no paramétrico y perezoso, lo que significa que no realiza suposiciones sobre la distribución de los datos y que no entrena explícitamente un modelo, sino que almacena todas las instancias de entrenamiento. Su funcionamiento se basa en identificar los k vecinos más cercanos a un nuevo punto, según una medida de distancia, y predecir la clase predominante entre ellos. Se explican sus variantes: KNeighborsClassifier y RadiusNeighborsClassifier, así como las opciones de peso por distancia o uniforme. A través del dataset de Iris, se demuestra cómo el algoritmo clasifica flores en función de características como largo y ancho del sépalo

o pétalo. Luego, se introduce KNN para regresión, donde la salida es continua y se calcula como la media de los valores de los vecinos más cercanos. En la segunda parte de la clase se presentan los Árboles de Decisión, que se construyen dividiendo los datos según atributos relevantes a través de condiciones lógicas. Cada nodo del árbol representa una pregunta sobre una característica, y las ramas conducen a posibles respuestas. Esta técnica resulta intuitiva, transparente y aplicable a una gran variedad de problemas, desde sistemas de recomendación hasta diagnóstico médico. Se resalta que tanto KNN como los árboles de decisión ofrecen soluciones efectivas en contextos donde se necesita interpretar fácilmente el razonamiento del modelo.

Clase 6: Aprendizaje Supervisado III – SVM y SGD

La última clase del bloque profundiza en dos componentes clave del aprendizaje supervisado: el algoritmo de Support Vector Machine (SVM) y el método de optimización conocido como Stochastic Gradient Descent (SGD). Se comienza con una introducción al concepto de clasificador lineal, explicando que el objetivo de una SVM es encontrar un hiperplano que separe con el mayor margen posible los datos de diferentes clases. Se introducen conceptos como hiperplano, vectores de soporte y margen máximo, los cuales son esenciales para comprender cómo las SVM logran una clasificación eficiente incluso con conjuntos de datos complejos. Se explica el "truco del kernel", una técnica que permite transformar datos no linealmente separables en un espacio de mayor dimensión donde sí puedan separarse linealmente. Se presentan los kernels más utilizados: lineal, polinómico, radial (RBF) y sigmoide, cada uno con sus características y aplicaciones. En la segunda parte de la clase se estudia el Stochastic Gradient Descent, un método de optimización ampliamente utilizado por su eficiencia, especialmente en conjuntos de datos grandes. A diferencia del descenso de gradiente tradicional, el SGD actualiza los parámetros del modelo utilizando una sola muestra por iteración, lo que acelera significativamente el proceso de aprendizaje. Se destaca la utilidad del SGD en modelos de regresión, redes neuronales y sistemas de recomendación. Finalmente, se propone una actividad práctica con Scikit-learn, invitando a los estudiantes a implementar una SVM para una tarea de clasificación, consolidando así los conocimientos adquiridos de manera aplicada.

2. Actividades integradoras:

Objetivo:
Consolidar los conocimientos adquiridos a lo largo de las clases mediante la creación de un mapa mental temático y la extracción de ideas principales, empleando herramientas digitales para facilitar el análisis, la reflexión crítica y la conexión entre conceptos clave.

Consigna General

Vas a crear un **Mapa Mental** que sintetice los principales temas abordados en las clases 1 a 6 del bloque "Aprendizaje Automático". Este mapa debe mostrar relaciones entre conceptos, ejemplos vistos y aplicaciones prácticas. Para ayudarte en este proceso, vas a utilizar **NotebookLM** u otra herramienta que permita organizar visualmente los contenidos a partir de textos o apuntes.

Pasos sugeridos:

1. **Revisión de contenido**
   Volvé a leer tus apuntes o repasá las presentaciones de las clases 1 a 6. Identificá los temas principales de cada una (por ejemplo: Pandas, Matplotlib, Regresión, KNN, Árboles de Decisión, SVM, etc.).
2. **Extracción de ideas clave**
   Usando **NotebookLM** (https://notebooklm.google.com/) o un documento digital, seleccioná entre **3 y 5 ideas principales por clase**. Asegurate de incluir definiciones, conceptos clave, herramientas utilizadas y alguna aplicación práctica. Podés copiar y pegar fragmentos directamente desde el material si lo necesitás.
3. **Elaboración del mapa mental**
   Con la información seleccionada, armá un **mapa mental** digital (podés usar herramientas como Coggle, Canva, Miro, MindMeister, o simplemente dibujarlo a mano y digitalizarlo). El mapa debe tener:

   - Un nodo central: "Aprendizaje Automático"
   - Ramas temáticas: una por cada clase (1 a 6)
   - Subramas con ideas clave, algoritmos y herramientas
   - Íconos o colores que ayuden a diferenciar los tipos de contenido

4. **Reflexión escrita**
   En un breve texto (entre 150 y 300 palabras), comentá:

   - ¿Qué clase te resultó más clara?
   - ¿Qué concepto te costó más entender?
   - ¿Qué tema te gustaría seguir investigando?

Entrega:

Subí al campus:

- El archivo de tu mapa mental (imagen, PDF o enlace compartido)
- (Opcional) La notebook de NotebookLM con tus notas o ideas organizadas
- Tu reflexión escrita

Durante los encuentros sincrónicos compartiremos las opiniones y los distintos mapas creados por los estudiantes.

3. Cierre:

· A lo largo de estas seis clases hemos recorrido juntos los fundamentos del Aprendizaje Automático, transitando desde los conceptos iniciales hasta la aplicación de algoritmos concretos. Hemos trabajado con herramientas poderosas como Pandas, Matplotlib y Scikit-learn, y explorado distintas técnicas de aprendizaje supervisado que nos permiten construir modelos predictivos útiles para una gran variedad de situaciones reales.

· Sabemos que el camino del aprendizaje no es lineal, y por eso esta clase de repaso es también una invitación a frenar un momento, mirar hacia atrás y reconocer tus propios avances. A veces solo hace falta releer un ejemplo, volver a ejecutar un código o compartir una duda con un compañero para que una idea termine de encajar.

· Te proponemos ahora reflexionar sobre tu proceso. Para ello, podés participar en el foro respondiendo a esta pregunta:

· 🔍 **¿Qué contenido sentís que dominás mejor y cuál necesitás repasar más?**

· Además, te invitamos a hacer una dinámica sencilla de retroalimentación rápida para ayudarte a consolidar lo aprendido:

· 🧠 **3 cosas que recordás**
🤯 **2 que te sorprendieron**
🚀 **1 que querés seguir explorando**

· Tu aporte será valioso no solo para vos, sino también para tus compañeros y docentes. ¡Gracias por el compromiso y el entusiasmo con el que venís participando en este recorrido!

.

4. Bibliografía

OBLIGATORIA

- HAN, R. (2019): *Matemáticas del Aprendizaje Automático. Introducción a la analítica de datos e Inteligencia Artificial.*
- JONES, H. (2019): *Aprendizaje Automático. El Aprendizaje Automático para principiantes que desean comprender aplicaciones, Inteligencia Artificial, Minería de Datos, Big Data y más*. Editorial Edición Kindle.
- RUSSELL, R. (2018): *Machine Learning. Guia Paso a Paso Para Implementar Algoritmos De Machine Learning Con Python*
- VIDALES, A. (2019) *Machine Learning Con Matlab*. Editorial Edición Kindle.
- CANE, A. (2019): *Programación Con Python. Guía completa para principiantes.*
- HERNÁNDEZ, V. (2019): *Aprendizaje Automático. Implementación en Inteligencia Artificial.* Editorial Edición Kindle.