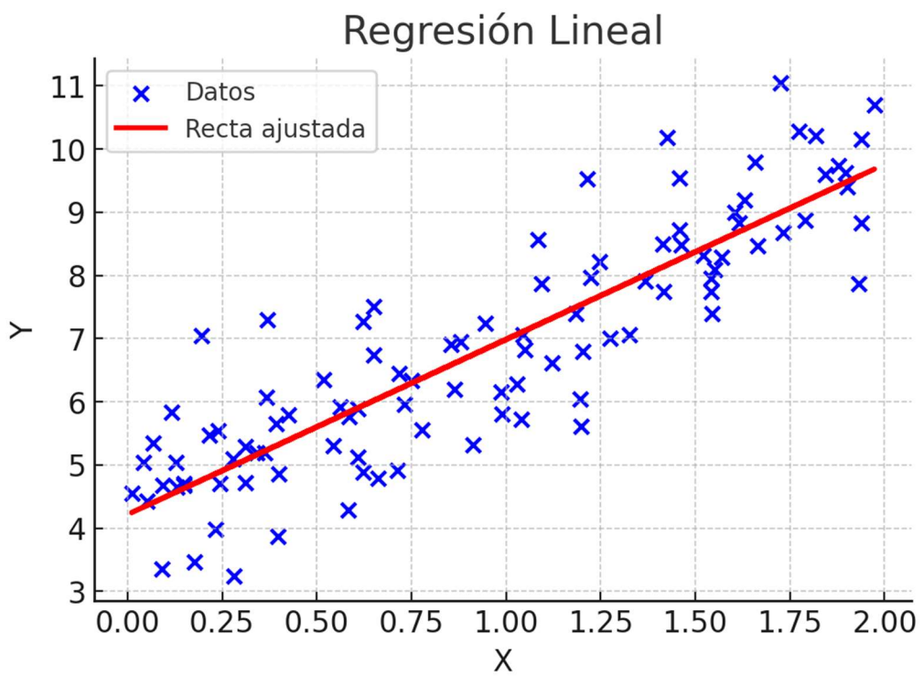
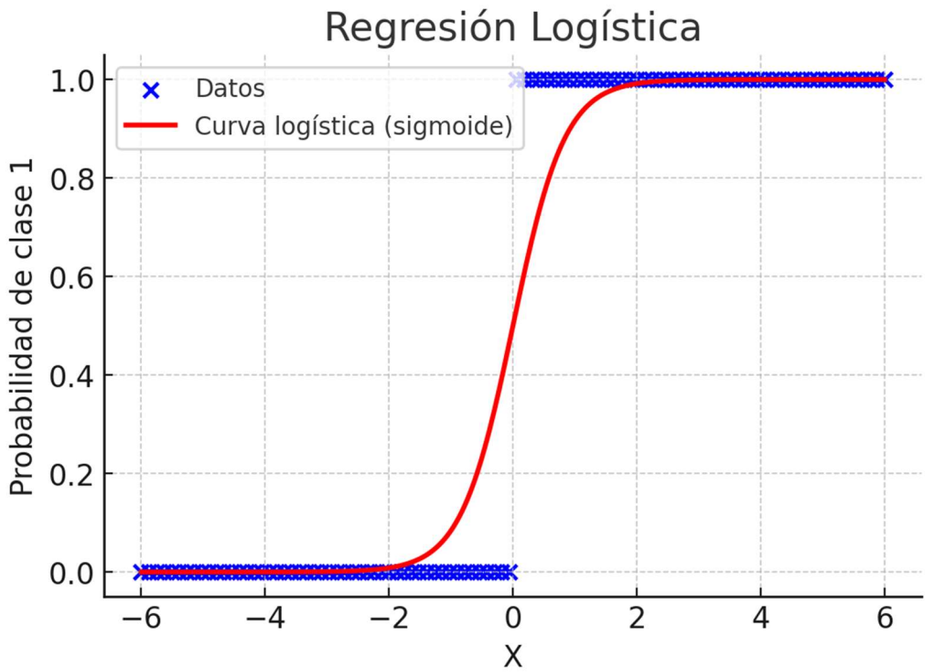
Modelo de regresión: Regresión líneal



Comparación de Modelos de Clasificación

1. Regresión Logística

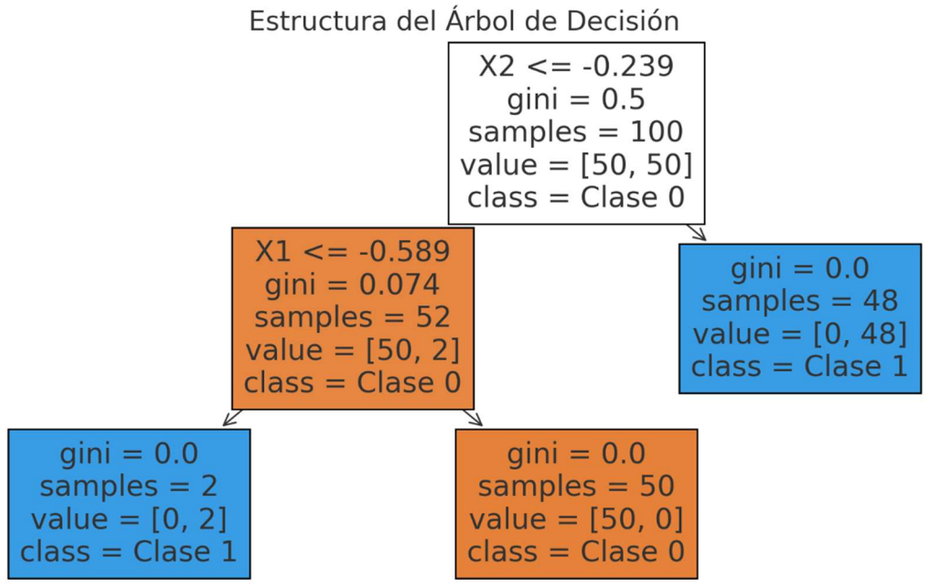
- **Tipo**: Modelo estadístico (lineal en los coeficientes).
- **Idea principal**: Modela la probabilidad de pertenencia a una clase usando una función logística (sigmoide).
- **Ventajas**:
    - Fácil de interpretar: coeficientes indican la importancia de cada variable.
    - Útil para problemas **binarios** y se extiende a multinomiales (con Softmax).
    - Muy rápido de entrenar.
- **Desventajas**:
    - Supone una relación **lineal** entre predictores y log-odds.
    - No maneja bien relaciones no lineales sin transformaciones.
- **Ejemplo de uso**: ¿Un cliente cancelará su suscripción? (Sí / No).



---

2. Árbol de Decisión

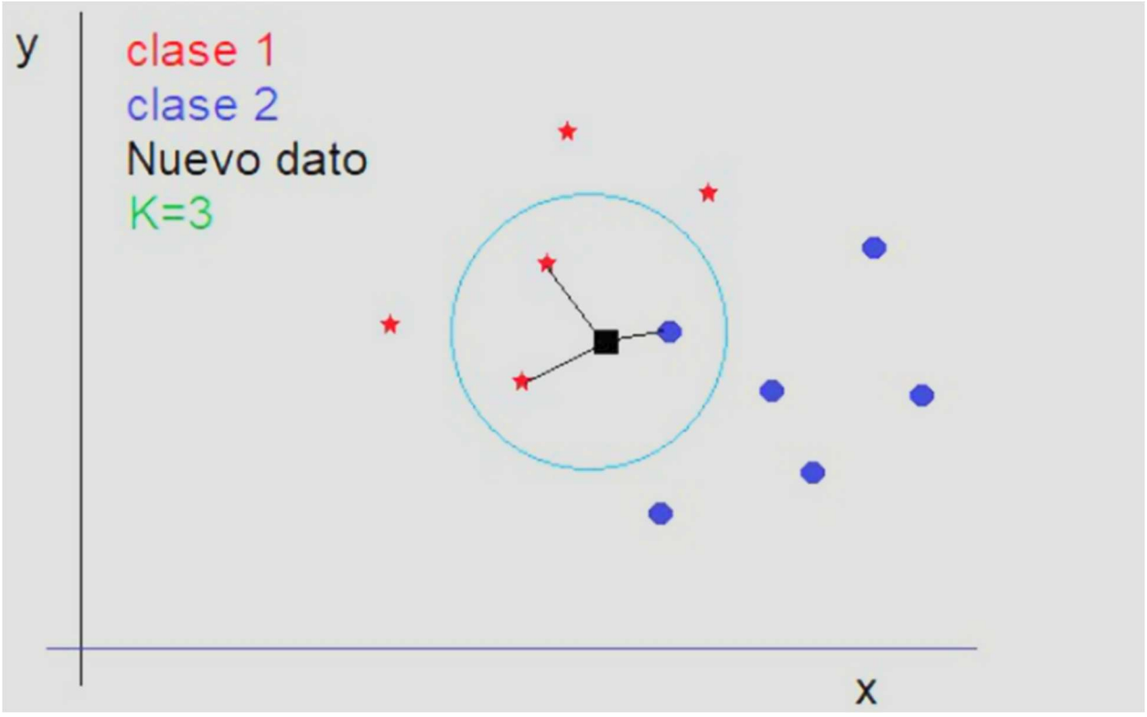
- **Tipo**: Modelo basado en reglas (estructuras jerárquicas).
- **Idea principal**: Divide el espacio de datos en regiones a partir de preguntas ("¿Edad > 40?", "¿Ingreso < 1000?").
- **Ventajas**:
  - Fácil de **visualizar e interpretar**.
  - Maneja bien variables categóricas y numéricas.
  - Captura relaciones **no lineales**.
- **Desventajas**:
  - Tienden a sobreajustar (overfitting) si no se podan.
  - Sensibles a cambios pequeños en los datos.
- **Ejemplo de uso**: Clasificación de pacientes en riesgo bajo/medio/alto de enfermedad.



---

3. K-Nearest Neighbors (KNN)

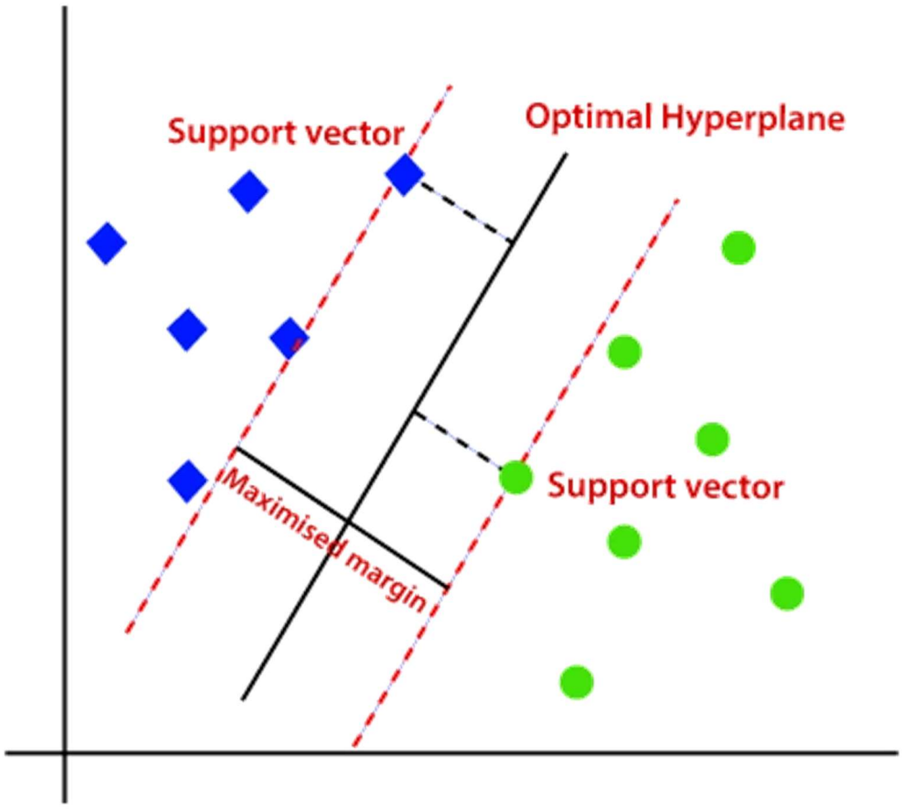
- **Tipo**: Algoritmo basado en instancias (lazy learning).
- **Idea principal**: Clasifica un punto según la mayoría de sus **vecinos más cercanos** (distancia euclídea, Manhattan, etc.).
- **Ventajas**:
  - Simple de entender e implementar.
  - No requiere entrenamiento explícito (almacena datos).
  - Captura fronteras complejas entre clases.
- **Desventajas**:
  - Costoso en predicción (se comparan todos los puntos).
  - Sensible a la escala de variables → requiere normalización.
  - Mal desempeño con muchos atributos irrelevantes.
- **Ejemplo de uso**: Clasificación de flores según medidas de pétalos y sépalos (Iris dataset).



---

4. Máquinas de Vectores de Soporte (SVM)

- **Tipo**: Modelo basado en hiperplanos.
- **Idea principal**: Encuentra el hiperplano que **maximiza el margen** entre clases.
- **Ventajas**:
  - Funciona bien en espacios de **alta dimensión**.
  - Kernel trick → permite capturar relaciones **no lineales**.
  - Generaliza bien si se ajustan parámetros.
- **Desventajas**:
  - Entrenamiento costoso en datasets grandes.
  - Parámetros (C, kernel, gamma) pueden ser difíciles de ajustar.
- **Ejemplo de uso**: Clasificación de spam vs no-spam en correos electrónicos.



Comparación General

Característica	Regresión Logística	Árbol de Decisión	KNN	SVM
Interpretabilidad	Fácil	Muy fácil	Simple	Difícil
No linealidad	❌ Limitada	✅ Sí	✅ Sí	✅ Sí
Velocidad de Entrenamiento	⭐ Rápido	Medio	Muy rápido (entrenamiento trivial)	Lento en datasets grandes
Velocidad de Predicción	Muy rápido	Medio	Lento (compara con todos los puntos)	Medio
Escalabilidad	Alta	Media	Baja	Media
Manejo de variables categóricas	Con codificación	✅ Naturalmente	❌ Necesita conversión	❌ Necesita conversión
Robustez al ruido	Media	❌ Baja (inestables)	❌ Baja	Alta

Característica	Regresión Logística	Árbol de Decisión	KNN	SVM
Casos de uso típicos	Probabilidades, riesgos	Decisiones, reglas	Recomendaciones, reconocimiento de patrones	Clasificación compleja, textos, imágenes

---

En resumen:

- Usar **Regresión Logística** si necesitamos **interpretar coeficientes y probabilidades**.
- Usar **Árboles de Decisión** si queremos **explicar el modelo** de manera clara.
- Usar **KNN** para **datasets pequeños** con fronteras complejas.
- Usar **SVM** para **alta dimensión y problemas no lineales**, aunque puede ser más costoso.

1. ¿Se pueden usar los 4 para problemas multinomiales?

Sí, los cuatro algoritmos pueden usarse para clasificación multinomial, aunque con diferentes mecanismos:

- **Regresión Logística**
    - Se generaliza con **Softmax** (regresión logística multinomial).
    - Asigna una probabilidad a cada clase y elige la mayor.
    - Muy usada en problemas con muchas clases.
- **Árboles de Decisión**
    - De forma natural soportan múltiples clases.
    - Las divisiones en los nodos se calculan buscando la mejor separación para todas las clases a la vez.
- **KNN**
    - También funciona directamente con varias clases.
    - El voto mayoritario entre vecinos puede ser entre 3, 5 o más clases.
- **SVM**

- Originalmente es binario, pero se extiende con estrategias:
  - **One-vs-Rest (OvR)**: un clasificador por clase contra el resto.
  - **One-vs-One (OvO)**: un clasificador por cada par de clases.
- Puede ser computacionalmente más costoso en datasets con muchas clases.

---

2. Mejor algoritmo según tipo de variables

Si hay más variables numéricas:

- **Mejores opciones**:
  - **SVM** → maneja muy bien espacios de alta dimensión con variables numéricas.
  - **Regresión Logística** → adecuada si las relaciones son cercanas a lineales.
  - **KNN** también puede funcionar, pero depende mucho de la escala (necesita normalización).

Los árboles también sirven, pero con muchas variables numéricas pueden sobreajustar si no se regulan (profundidad, poda, etc.).

Si hay más variables categóricas:

- **Mejor opción**:
  - **Árboles de Decisión** → trabajan naturalmente con categorías, no requieren codificación numérica complicada.
  - **Regresión Logística, KNN y SVM** necesitan convertir categorías a números (one-hot encoding, embeddings, etc.), lo que puede aumentar mucho la dimensionalidad.

Conclusiones

- **Problemas multinomiales** → Todos sirven, pero:
  - Para **muchas clases** y necesidad de **probabilidades claras** → **Regresión Logística Multinomial**.
  - Para **explicación sencilla** → **Árbol de Decisión**.
  - Para **fronteras complejas en datos numéricos** → **SVM** o **KNN**.
- **Datos mayormente numéricos** → **SVM** y **Regresión Logística** suelen rendir mejor.

- **Datos mayormente categóricos** → **Árboles de Decisión** son la mejor opción (los demás requieren transformar categorías).