

Reglas preestablecidas y aprendizaje automático

Cómo distinguir cálculos y decisiones programadas de modelos de regresión y clasificación

Un programa puede calcular un sueldo, asignar una categoría o producir una respuesta en segundos sin utilizar aprendizaje automático. Para reconocer un caso de aprendizaje automático, necesitamos saber **cómo se obtuvo el criterio que relaciona los datos de entrada con la respuesta**. Mirar solamente el resultado puede llevarnos a una conclusión equivocada.

Este apunte explica esa diferencia mediante situaciones cotidianas. Compararemos la liquidación de un sueldo con la estimación de un salario, el cálculo de un alquiler pactado con la estimación de su precio de mercado y los filtros manuales de correo con los clasificadores entrenados. También veremos ejemplos de consumo eléctrico, transporte, educación, atención de consultas y control de productos.

La idea que vamos a trabajar

En un sistema con reglas preestablecidas, una persona define de antemano la fórmula, las condiciones o el procedimiento que debe aplicar el programa. En aprendizaje automático, se utiliza un procedimiento de entrenamiento para obtener, a partir de ejemplos, un modelo que relacione las entradas con las salidas. Después, ese modelo se usa para resolver casos nuevos.

Por eso, **obtener un número no demuestra que exista regresión de aprendizaje automático**. Multiplicar las horas trabajadas por una tarifa conocida produce un número, pero sigue siendo un cálculo programado. De manera similar, **asignar una categoría no demuestra que exista clasificación mediante aprendizaje automático**. Marcar como aprobado a quien tiene una nota igual o mayor que 6 puede resolverse con una condición escrita por una persona.

Qué significa trabajar sin reglas preestablecidas

En este material, esa expresión significa que no escribimos de antemano toda la relación entre las entradas y la respuesta que queremos estimar. No significa que la computadora trabaje sin instrucciones. Las personas siguen definiendo el problema, eligiendo datos y programando el procedimiento de aprendizaje. Incluso el modelo resultante puede contener fórmulas o reglas.

Al finalizar, deberías poder explicar de dónde sale una respuesta, identificar si hubo entrenamiento y distinguir regresión de clasificación cuando efectivamente se utiliza aprendizaje automático.

Datos de los ejemplos. Todos los importes, porcentajes, registros y situaciones numéricas son ficticios y se usan con fines didácticos. Las liquidaciones y los contratos simplificados no representan normativa laboral ni condiciones actuales del mercado.

1 Cómo se obtiene el criterio de resolución

Cuando una persona escribe las reglas

Imaginemos que un estacionamiento cobra \$2.000 por hora. Si un vehículo permanece 3 horas, el programa multiplica 3 por 2.000 y obtiene \$6.000. La tarifa y la operación ya estaban definidas. No hace falta mostrarle miles de tickets para que descubra cómo cobrar: alcanza con escribir la regla e ingresar el tiempo de permanencia.

Las reglas pueden tomar muchas formas. Pueden ser una fórmula matemática, una lista de valores permitidos, una tabla de tarifas o condiciones del tipo «si ocurre esto, hacer aquello». Un sistema de liquidación puede tener cientos de condiciones y seguir funcionando exclusivamente con reglas preestablecidas. Su complejidad no lo convierte en un sistema que aprende.

Estos sistemas también usan datos. El programa necesita saber las horas, las tarifas, las categorías o los importes. La diferencia es que esos datos se utilizan para **aplicar un criterio que ya estaba definido**. Consultar una base con millones de registros tampoco implica, por sí solo, entrenar un modelo.

Cuando el criterio se obtiene a partir de ejemplos

Ahora queremos estimar cuánto tardará un vehículo en llegar a destino. Conocer la distancia no alcanza para determinar exactamente el tiempo: también influyen el tránsito, la hora, el recorrido y otras condiciones. Podemos reunir viajes anteriores con esas características y con sus duraciones reales. Un algoritmo de aprendizaje puede usar esos ejemplos para construir un modelo que estime la duración de otro viaje.

La persona no escribe cada combinación posible de tránsito, distancia y horario con su respuesta. Define qué se quiere estimar y prepara ejemplos adecuados. El entrenamiento busca una relación útil dentro del tipo de modelo elegido. Esa relación puede ser imperfecta, porque los datos no contienen toda la información y los casos nuevos pueden ser diferentes.

Aspecto	Reglas preestablecidas	Aprendizaje automático
Origen del criterio	Una persona establece la fórmula o las condiciones.	El entrenamiento obtiene relaciones a partir de datos.
Uso de ejemplos previos	Pueden servir para probar o diseñar el sistema.	Sirven para ajustar el modelo.
Caso nuevo	Se aplican las reglas escritas.	Se aplica el modelo ya entrenado.
Cambio del criterio	Se modifica la regla o su configuración.	Se vuelve a entrenar o actualizar el modelo mediante un proceso previsto.

Una estimación también puede hacerse con una regla manual, por ejemplo «cada kilómetro demanda 2 minutos». Aunque esa respuesta sea aproximada, no hubo aprendizaje automático. **La diferencia central está en el origen del criterio, no en si la respuesta es exacta o aproximada.**

2 Qué se aprende y cuándo se utiliza

Algoritmo y modelo

Un algoritmo es un procedimiento compuesto por instrucciones. Tanto el programa que liquida sueldos como el que entrena una regresión utilizan algoritmos. En aprendizaje automático conviene distinguir el **algoritmo de entrenamiento**, que procesa ejemplos, del **modelo entrenado**, que conserva lo aprendido y permite realizar predicciones.

Por ejemplo, en una regresión lineal se elige una forma de relación entre las variables y el entrenamiento determina sus coeficientes. En un árbol de decisión, el entrenamiento selecciona condiciones para separar casos. La persona decide cómo se aprenderá; los datos influyen en la relación específica que queda ajustada.

Datos de entrada y respuesta conocida

En aprendizaje supervisado, cada ejemplo de entrenamiento incluye características de entrada y una respuesta conocida. A esa respuesta la llamamos **variable objetivo**, y muchas veces también etiqueta. Las características son la información disponible para estimarla. Entrenamos con respuestas conocidas y evaluamos qué ocurre con ejemplos que no se usaron para ajustar el modelo. [1]

Problema	Características de entrada	Variable objetivo
Estimar un alquiler	Superficie, ubicación, estado, ambientes.	Importe mensual del alquiler.
Detectar spam	Información obtenida del texto, enlaces y remitente.	Spam o correo legítimo.
Estimar una duración	Distancia, hora, recorrido, tránsito disponible.	Minutos de duración del viaje.

Entrenamiento y predicción son etapas diferentes

Durante el entrenamiento se utilizan ejemplos para construir o ajustar el modelo. En la predicción, también llamada inferencia, se proporciona un caso nuevo y se aplica el modelo que ya existe. Si estimamos el alquiler de un departamento, ingresamos sus características; el importe que buscamos estimar no debe entrar como dato de ese mismo caso.

Para evaluar el modelo sí necesitamos conocer las respuestas de algunos casos reservados. Se las ocultamos al modelo mientras predice y después comparamos. Si estimó \$640.000 y el valor observado era \$665.000, podemos medir la diferencia. En spam, comprobamos cuántos correos clasificó correctamente y qué tipos de errores cometió.

Un modelo entrenado de forma estática no cambia simplemente porque recibe nuevas consultas. Para incorporar nuevos ejemplos hay que ejecutar un proceso de actualización o reentrenamiento. Existen sistemas diseñados para aprender de manera continua, pero esa capacidad debe implementarse y supervisarse. [4]

3 El tipo de salida y el origen del criterio

Dos preguntas diferentes

La primera pregunta es cómo se obtuvo el criterio de resolución: ¿lo definió una persona o se obtuvo mediante entrenamiento con datos? La segunda pregunta es qué representa la salida: ¿una magnitud numérica o una categoría? Si mezclamos estas preguntas, terminamos llamando regresión a cualquier cuenta y clasificación de aprendizaje automático a cualquier condición.

Dentro del aprendizaje supervisado, hablamos de **regresión** cuando el modelo estima una magnitud numérica, como un importe, una temperatura o una duración. Hablamos de **clasificación** cuando aprende a asignar una clase, como spam o legítimo. Estas definiciones describen tareas de aprendizaje supervisado. [2]

Tipo de salida		Criterio escrito de antemano	Criterio aprendido con ejemplos
Número o magnitud	o	Calcular el sueldo con horas, tarifas, adicionales y descuentos conocidos.	Estimar un salario de mercado con un modelo entrenado con salarios observados.
Categoría o clase	o	Asignar «aprobado» cuando la nota final es igual o mayor que 6.	Predecir si un estudiante aprobará usando un modelo entrenado con cohortes anteriores.

El significado del número también importa

Supongamos que un sistema devuelve 0 para correo legítimo y 1 para spam. Aunque vemos números, esos valores representan nombres de clases. No estamos estimando una cantidad de spam: usamos códigos para dos categorías. Si el criterio se aprendió con correos etiquetados, la tarea es clasificación.

También puede ocurrir que un clasificador calcule una probabilidad, como 0,90 para la clase spam. Ese número ayuda a tomar una decisión sobre una categoría. Por eso, ver un decimal no alcanza para concluir que el problema sea de regresión. Hay que observar el objetivo del modelo y cómo fue entrenado.

Clasificar en sentido cotidiano y clasificar con aprendizaje automático

Ordenar productos por tamaño, separar personas por edad o asignar un trámite a una oficina son formas de clasificar en el lenguaje cotidiano. Pueden realizarse mediante reglas. En una materia de aprendizaje automático, cuando hablamos de un modelo de clasificación nos referimos a un modelo que aprendió a predecir clases a partir de ejemplos.

Decir «el programa clasifica» puede ser correcto, pero queda incompleto. Para saber si utiliza aprendizaje automático debemos agregar **cómo obtuvo el criterio de clasificación**. Esa explicación es más importante que el nombre del programa, su velocidad o el formato de su respuesta.

4 Liquidar un sueldo con reglas conocidas

El problema que necesitamos resolver

Una empresa quiere liquidar el sueldo de una persona. Ya conoce el sueldo básico, las horas extras realizadas, el valor de cada hora, los adicionales y los descuentos que debe aplicar. La tarea consiste en ejecutar correctamente esas condiciones. No necesita descubrir a partir de empleados anteriores cuánto debería dar la cuenta.

Para simplificar, supongamos que todos los conceptos de esta liquidación ficticia son los siguientes. El valor de la hora extra ya está establecido; no estamos explicando cómo se determina en una liquidación real.

Concepto	Dato del ejemplo	Importe
Sueldo básico	Importe fijado	\$900.000
Horas extras	10 horas a \$7.500 cada una	\$75.000
Adicional	Importe fijado	\$25.000
Descuentos	Importe total conocido	-\$150.000
Sueldo neto	Resultado de la liquidación	\$850.000

$$900.000 + 75.000 + 25.000 - 150.000 = 850.000$$

El resultado es \$850.000 porque se aplicaron las operaciones previstas a los datos de esa persona. Si trabajara 12 horas extras, se usaría la misma regla con un dato distinto. Obtener otra respuesta no significa que el programa haya aprendido: significa que cambió una entrada.

Por qué este caso no es regresión de aprendizaje automático

No se entrenó un modelo con sueldos anteriores. Tampoco se ajustaron coeficientes para reducir errores de predicción. La relación entre los datos y el resultado ya estaba definida. Multiplicar, sumar, restar o aplicar porcentajes son operaciones matemáticas, pero su presencia no demuestra aprendizaje.

Si el sistema procesa diez mil empleados, continúa aplicando las mismas reglas, con las excepciones que se hayan programado. Puede consultar legajos y escalas en una base de datos o importar una nueva tarifa automáticamente. Ninguna de esas acciones equivale, por sí sola, a aprender una relación entre variables.

Qué pasaría si entrenáramos un modelo para imitar la liquidación

Sería posible entrenar una regresión con liquidaciones anteriores para aproximar sus resultados. En ese caso sí habría entrenamiento, aunque la tarea original tuviera reglas conocidas. Sin embargo, agregaríamos una aproximación donde necesitamos respetar condiciones exactas. Si las reglas y todos los datos están disponibles, implementarlas directamente suele ser la solución adecuada.

Diagnóstico del ejemplo. Es un cálculo con reglas preestablecidas. La razón no es que resulte sencillo: es que conocemos de antemano la relación que debe aplicarse.

5 Estimar un salario a partir de otros casos

Ahora cambia la pregunta

Una persona quiere conocer qué salario mensual podría observarse para un puesto similar al suyo. Todavía no tiene un importe pactado que deba liquidarse. Cuenta con información sobre experiencia, responsabilidades, jornada, sector y ubicación. En este caso buscamos estimar un valor de mercado, que puede variar entre organizaciones incluso para perfiles parecidos.

Los siguientes registros representan salarios brutos mensuales ficticios para puestos de una misma familia, con igual jornada y en un mismo período. Usamos definiciones comparables: no mezclamos importes netos con brutos ni valores mensuales con anuales.

Caso	Experiencia	Responsabilidad	Salario observado
A	1 año	Inicial	\$900.000
B	3 años	Intermedia	\$1.250.000
C	5 años	Intermedia	\$1.550.000
D	5 años	Coordinación	\$1.900.000
E	8 años	Coordinación	\$2.200.000

Esta muestra ilustra la estructura de los datos. Un servicio real necesitaría registros adecuados a su alcance y una evaluación con casos separados del entrenamiento.

Qué hace el entrenamiento

El algoritmo utiliza las características y los salarios conocidos para ajustar un modelo. En una regresión lineal, por ejemplo, calcula coeficientes que permiten combinar las variables. No le imponemos necesariamente que cada año de experiencia valga una suma fija: esa relación se estima con los datos, dentro de las posibilidades del modelo elegido.

Para un perfil nuevo, por ejemplo con 4 años de experiencia y responsabilidad intermedia, el modelo devuelve un importe estimado. Una oferta concreta puede diferir por factores no registrados o cambios del mercado.

La diferencia con liquidar el sueldo

En la liquidación preguntábamos cuánto corresponde pagar al aplicar condiciones conocidas. Aquí preguntamos qué valor podría observarse para un perfil, usando lo ocurrido en otros casos. Ambos resultados son dinero, pero el procedimiento y el significado de la respuesta son diferentes.

Además, un salario observado no equivale a un salario justo. Un modelo puede reproducir diferencias presentes en los datos. Su estimación describe patrones del conjunto utilizado; no establece por sí misma cuánto debería ganar una persona.

Diagnóstico del ejemplo. Si el importe se estima con un modelo entrenado con salarios observados, estamos ante regresión de aprendizaje automático. Si alguien fija manualmente una fórmula salarial, esa fórmula sigue siendo una regla, aunque produzca una estimación.

6 Calcular un alquiler mediante condiciones fijadas

Actualizar un importe pactado

Supongamos un contrato ficticio que establece un importe de \$500.000 y un incremento del 10 % para el período que estamos calculando. El sistema conoce ambos datos y aplica la operación indicada. La tarea no consiste en estimar cuánto se pagaría por una vivienda similar en el mercado, sino en calcular el importe resultante de una condición ya acordada.

$$500.000 \times 1,10 = 550.000$$

El nuevo importe es \$550.000. Aunque ese valor corresponda a un mes futuro, no hubo aprendizaje automático. La fecha de la respuesta no determina el método utilizado: se puede calcular un importe futuro con reglas conocidas y se puede estimar un valor actual con un modelo aprendido.

Si el porcentaje se obtiene de una tabla externa, el razonamiento no cambia. Buscar un valor y aplicarlo automáticamente es una operación programada. Para hablar de aprendizaje tendríamos que identificar un procedimiento que ajuste un modelo a partir de datos, no solamente una consulta a una fuente.

Estimar un precio con una fórmula manual

Una inmobiliaria también podría inventar una regla práctica: cobrar \$200.000 de base y sumar \$8.000 por cada metro cuadrado. Para un departamento de 50 m², esa regla daría el siguiente resultado.

$$200.000 + 8.000 \times 50 = 600.000$$

En este segundo caso hablamos de una estimación, porque la fórmula intenta aproximar un precio posible. Sin embargo, si una persona eligió esos números sin entrenar un modelo, seguimos frente a una regla preestablecida. Ser aproximado, usar varias variables o incorporar la experiencia de un especialista no basta para convertirlo en aprendizaje automático.

Los mismos símbolos pueden tener orígenes diferentes

Una expresión del tipo «importe base más valor por metro cuadrado» podría ser una regla comercial o el resultado de una regresión lineal. La forma de la fórmula no permite decidirlo. Debemos preguntar **de dónde salieron sus coeficientes**: si fueron fijados directamente o si se estimaron mediante un procedimiento de ajuste con ejemplos.

Una persona puede analizar datos y luego redactar reglas manualmente. En ese caso existe análisis humano apoyado en datos, pero no necesariamente entrenamiento automático. En cambio, si un procedimiento ajusta los coeficientes de una regresión usando observaciones, sí se está construyendo un modelo aprendido, aunque se utilice una planilla de cálculo.

Diagnóstico de los dos ejemplos. El incremento pactado es un cálculo por reglas. La fórmula que la inmobiliaria decidió manualmente es una estimación por reglas. Ninguno de los dos se vuelve aprendizaje automático por devolver un precio.

7 Estimar un alquiler con una regresión entrenada

Un ejemplo pequeño de aprendizaje

Ahora contamos con cinco alquileres mensuales ficticios de viviendas comparables, observados en un mismo período. Para mostrar el mecanismo usamos solamente la superficie. En un problema real también serían relevantes la ubicación, el estado, los ambientes y otras características.

Vivienda	Superficie en m ²	Alquiler mensual observado
A	30	\$450.000
B	40	\$500.000
C	50	\$600.000
D	60	\$670.000
E	70	\$780.000

Si ajustamos una regresión lineal por mínimos cuadrados a estos cinco registros, obtenemos un importe base de \$185.000 y un coeficiente de \$8.300 por m². Mínimos cuadrados significa que se eligen los coeficientes para minimizar la suma de los errores al cuadrado en los datos de entrenamiento. La relación ajustada es:

$$\text{Alquiler estimado} = 185.000 + 8.300 \times \text{superficie}$$

Los coeficientes se calcularon usando los ejemplos. Por eso esta fórmula representa un modelo aprendido. La forma de una recta se eligió de antemano, pero sus valores se ajustaron con los datos. Si utilizáramos otros registros, podrían obtenerse otros coeficientes.

Aplicar el modelo a una vivienda nueva

Para una vivienda de 55 m², el modelo calcula \$185.000 más \$8.300 multiplicado por 55. La estimación resultante es **\$641.500**. En esta etapa ya no estamos entrenando: estamos aplicando el modelo que obtuvimos antes.

Si después observamos que esa vivienda se alquiló por \$665.000, la diferencia absoluta es \$23.500. Ese dato permite evaluar una predicción nueva. Un solo caso no alcanza para medir el desempeño general, y los cinco registros de entrenamiento tampoco justifican usar el modelo en el mercado real.

Por qué aprender no es copiar cada respuesta

Para 40 m², la fórmula predice \$517.000, aunque el registro observado era \$500.000. Una recta no tiene por qué pasar por todos los puntos. El entrenamiento busca un ajuste conjunto, que admite diferencias entre la relación representada y los casos particulares.

El coeficiente tampoco prueba que agregar un metro cuadrado cause exactamente \$8.300 de aumento en cualquier vivienda. Describe una asociación dentro de estos datos y este modelo. **La presencia de una fórmula no elimina el aprendizaje: lo decisivo es cómo se obtuvo esa fórmula.**

8 Otros ejemplos de cálculos y regresión

Consumo eléctrico y facturación

Si conocemos el consumo medido de una vivienda y una tarifa fija ficticia de \$100 por kWh, calcular el cargo por 250 kWh consiste en multiplicar 250 por 100. El resultado es \$25.000. Aunque el sistema consulte miles de medidores, esta parte del proceso aplica una tarifa conocida. No necesita aprender cuánto cobrar para cada consumo.

Otra tarea sería estimar cuántos kWh consumirá la vivienda el mes próximo. Podemos entrenar un modelo con consumos anteriores, temperatura, cantidad de habitantes y características del hogar, usando en cada ejemplo la información que estaría disponible al momento de predecir. La variable objetivo es una cantidad de energía. Si la relación se aprende con esos registros, es una tarea de regresión.

También podemos combinar las dos etapas: primero el modelo estima el consumo y después una fórmula aplica la tarifa. La factura proyectada tendrá incertidumbre por el consumo estimado. La multiplicación final continúa siendo un cálculo con reglas, aunque forme parte de un sistema que incluye aprendizaje automático.

Precio de un viaje y duración del recorrido

En un servicio ficticio, el precio se fija en \$1.500 de base más \$800 por kilómetro. Si el recorrido facturable es de 5 km, el importe es \$5.500. La fórmula comercial ya estaba definida y determina el cobro. No estamos ante una regresión solo porque usamos distancia y obtenemos dinero.

Si queremos estimar la duración del viaje con datos de recorridos anteriores, podemos entrenar una regresión que relacione distancia, horario y condiciones de tránsito con minutos de viaje. Dos trayectos de 5 km pueden durar tiempos diferentes. El modelo intenta representar esa variación con la información disponible.

También sería posible estimar la duración mediante una regla manual, como «3 minutos por kilómetro». Eso produciría una predicción numérica, pero no un modelo aprendido. Para identificar el método debemos conocer el procedimiento utilizado, no solamente la pregunta que se intenta responder.

Promedio de notas y estimación de una nota futura

Calcular el promedio de 7, 8 y 9 da como resultado 8. La operación está completamente especificada: sumar las notas y dividir por tres. No se necesita entrenamiento. Si miles de estudiantes tienen su promedio calculado de esa manera, sigue siendo el mismo procedimiento aritmético.

Estimar una nota todavía desconocida a partir de trabajos previos y otros registros sería una tarea diferente. Podría plantearse como regresión si se entrena un modelo para predecir esa magnitud. Ese resultado no reemplaza la evaluación del estudiante ni determina la nota que corresponde asignarle: es una estimación basada en datos.

En los tres ámbitos aparecen números. La distinción se mantiene: **aplicar una relación ya especificada** y **estimar una relación a partir de ejemplos** son procedimientos diferentes.

9 Detectar spam mediante reglas manuales

Un filtro de palabras prohibidas

Una persona configura un filtro que envía un correo a spam si contiene alguna de estas expresiones: «ganaste dinero», «viagra» o «herencia». Para este ejemplo, el programa busca esas palabras o frases exactas. Si encuentra al menos una, asigna la categoría spam; si no encuentra ninguna, deja pasar el mensaje.

La salida es una categoría, pero el programa no aprendió a reconocerla. Una persona decidió cuáles serían las señales y qué acción correspondía a cada una. Podemos describirlo como una clasificación por reglas, sin afirmar que sea un modelo de clasificación entrenado.

Correo recibido	Resultado del filtro	Qué permite observar
«Ganaste dinero y podés cobrar hoy».	Spam.	Coincide con una expresión de la lista.
«g_anaste d1nero y podés cobrar hoy».	No se marca como spam por esas expresiones.	La variante evita la coincidencia exacta.
«Te envío el material de clase sobre herencia genética».	Spam.	La palabra aparece en un correo legítimo.

Dos formas de equivocarse

En el segundo mensaje, el filtro deja pasar un correo que queríamos detectar. En el tercero, bloquea un correo legítimo. El primer error se denomina falso negativo cuando tomamos spam como clase positiva; el segundo es un falso positivo. No basta con detectar muchos mensajes molestos: también importa evitar el bloqueo de correos útiles.

Para reconocer la variante «g_anaste d1nero», alguien podría agregar esa expresión a la lista. También podría programar transformaciones, como reemplazar determinados números por letras o quitar algunos separadores. Esas mejoras seguirían siendo reglas si fueron definidas manualmente. Pueden ser útiles, pero no implican necesariamente entrenamiento.

Qué limita este ejemplo

La dificultad del filtro sencillo es que depende de coincidencias muy específicas y trata cada aparición de la misma manera. Una lista no distingue automáticamente si «herencia» aparece en un engaño, en una consulta familiar o en una explicación de biología. Para cubrir esas diferencias con reglas, habría que ampliar el procedimiento.

Eso no significa que todo sistema de reglas sea rudimentario o falle siempre. Puede incluir remitentes permitidos, combinaciones de expresiones y excepciones. El punto del ejemplo es identificar quién estableció las condiciones. **Una lista más larga sigue siendo una lista programada si el sistema no aprende a construir su criterio con ejemplos.**

10 Detectar spam con un modelo entrenado

Aprender con correos etiquetados

Partimos de 10.000 correos legítimos y 10.000 correos identificados como spam. Estas cantidades sirven para imaginar el ejercicio; no constituyen una garantía de calidad ni un requisito universal. Reservamos una parte para evaluación y usamos la parte de entrenamiento para construir el modelo.

Antes del entrenamiento, transformamos la información de los correos en características que el algoritmo pueda procesar. Podríamos representar palabras, fragmentos de caracteres, cantidad de enlaces y ciertos datos del remitente. El modelo solo puede aprovechar la información que efectivamente se le proporciona; no analiza automáticamente todos los aspectos posibles del mensaje.

El algoritmo relaciona esas características con las etiquetas conocidas. Por ejemplo, puede aprender que una combinación de expresiones, enlaces y rasgos del remitente aparece con mayor frecuencia en mensajes marcados como spam. La importancia de cada señal se obtiene mediante el entrenamiento, en lugar de redactar una lista completa de condiciones para todos los correos posibles.

Qué ocurre con un correo nuevo

Al llegar un mensaje, se lo representa de la misma manera que a los ejemplos de entrenamiento y se aplica el modelo. Puede devolver una clase directamente o una puntuación que luego se utiliza para elegir una clase.

Un modelo podría reconocer indicios de spam aunque no aparezca la frase exacta «ganaste dinero». Para lograrlo debe haber aprendido señales que también estén presentes en el caso nuevo. Eso se llama **generalizar**: utilizar relaciones obtenidas de ejemplos anteriores para resolver otros casos.

Cómo reconocer variaciones del texto

No es correcto garantizar que cualquier modelo detectará «g_anaste d1nero». Si solo representa palabras completas, la variante puede convertirse en una entrada desconocida. Representar pequeños fragmentos de caracteres puede conservar similitudes entre escrituras y ayudar frente a cambios del texto. Su eficacia debe comprobarse con ejemplos apropiados. [3]

Detectar una variante nunca vista y actualizar el modelo son cosas distintas. En el primer caso se aplica lo ya aprendido. En el segundo se incorporan nuevos ejemplos mediante un proceso de entrenamiento. Recibir «g_anaste d1nero» no modifica por sí solo un modelo estático.

Qué mejora podemos esperar

El aprendizaje automático permite combinar señales y aprender patrones difíciles de enumerar manualmente. Puede reducir la necesidad de agregar cada variante como una regla independiente, pero también puede equivocarse, bloquear correos legítimos o quedar desactualizado. La mejora se demuestra comparando resultados en correos reservados, no por el solo hecho de haber usado un modelo.

11 Clasificación en educación y atención de consultas

Determinar la aprobación con una condición conocida

Una materia ficticia establece que una nota final de 6 o más significa aprobado. Si el estudiante obtuvo 7, el sistema asigna «aprobado». La nota ya está disponible y el criterio institucional también. No hace falta entrenar con resultados de años anteriores para descubrir qué hacer con ese 7.

Si además se exige un porcentaje de asistencia, podemos agregar esa condición. Tener dos, diez o cien requisitos no cambia el origen del criterio. El sistema aplica una definición establecida. La categoría «aprobado» se determina mediante reglas.

Predecir un resultado antes de conocer la nota final

Otra pregunta sería si un estudiante probablemente aprobará al terminar el curso. A mitad del período conocemos entregas, asistencia acumulada y evaluaciones realizadas, pero todavía no conocemos la nota final. Podemos entrenar un clasificador con esos datos de cohortes anteriores y con el resultado que finalmente obtuvo cada estudiante.

Para que el ejemplo sea válido, las características históricas deben representar lo que se sabía a mitad del curso. Usar la nota final para predecir si aprobará en ese momento introduciría información que todavía no existe cuando se necesita la predicción. Esa filtración se conoce como fuga de información o data leakage.

La predicción puede servir para ofrecer apoyo, pero no asigna la condición académica definitiva. Una persona a la que el modelo atribuye mayor riesgo puede aprobar después. La regla que determina la aprobación y el modelo que intenta anticiparla cumplen funciones distintas.

Derivar consultas por palabras o por patrones aprendidos

Una organización recibe consultas y debe enviarlas a Facturación o Soporte técnico. Puede programar «si el texto contiene factura, enviar a Facturación; si contiene contraseña, enviar a Soporte técnico». Esa es una clasificación por reglas. Alguien escribió las asociaciones entre palabras y destinos.

También puede reunir miles de consultas ya resueltas y la categoría que correspondió a cada una. Un clasificador entrenado con esos ejemplos podría asociar expresiones como «me cobraron dos veces» con Facturación, aunque no aparezca la palabra «factura». La posibilidad depende de los datos y de cómo se representa el texto.

Si el usuario elige la categoría en un formulario y el sistema se limita a enviarla al área indicada, tampoco existe clasificación aprendida en esa etapa. El programa está utilizando una elección ya proporcionada, no infiriendo una categoría desconocida.

Qué comparar. En educación, distinguimos aplicar requisitos de anticipar un resultado. En las consultas, distinguimos ejecutar asociaciones redactadas de aprender asociaciones con casos etiquetados. La salida puede ser la misma clase de dato, pero su origen cambia.

12 Clasificación de productos y objetos

Asignar una categoría de tamaño

Una fábrica decide que los envases de menos de 500 ml pertenecen a la categoría pequeña y los de 500 ml o más a la categoría grande. Un sensor mide el volumen y el programa aplica la condición. Un envase de 450 ml queda en la categoría pequeña porque así fue definida, sin necesidad de aprender de otros envases.

Podríamos agregar una categoría mediana o cambiar los límites. El sistema seguiría aplicando reglas fijadas por la fábrica. La presencia de sensores, automatización o muchas mediciones no cambia ese hecho.

Reconocer el tipo de objeto a partir de una imagen

Ahora queremos reconocer si una imagen muestra una botella, una lata o una caja. Una alternativa con reglas sería programar condiciones sobre formas y proporciones. Por ejemplo, decidir que un objeto de cierta altura y con una región angosta en la parte superior se considera botella. Esas condiciones podrían resultar útiles en un entorno controlado, aunque tengan dificultades con perspectivas o diseños diferentes.

Una alternativa con aprendizaje automático consiste en entrenar un clasificador con imágenes etiquetadas como botella, lata o caja. Las categorías que queremos reconocer siguen siendo definidas por personas. Lo que se aprende es la relación entre la información visual de los ejemplos y esas categorías.

Para una imagen nueva, el modelo devuelve una clase o puntuaciones para las clases. El sistema no necesita que una persona escriba una regla para cada fotografía. Sin embargo, puede fallar con objetos poco representados, imágenes borrosas o condiciones de iluminación diferentes de las del entrenamiento.

Controlar productos con una especificación

Supongamos que una pieza debe medir entre 9,8 y 10,2 cm. Si el sensor informa 10,5 cm, una regla puede marcarla como fuera de tolerancia. El límite ya está fijado y tenemos la medición necesaria. Se trata de una clasificación por reglas, aunque la categoría resultante sea «aceptable» o «rechazada».

Si queremos detectar defectos visuales difíciles de describir con una única medición, podemos entrenar un modelo con fotografías de piezas inspeccionadas y etiquetas de calidad. Allí el criterio visual se aprende a partir de ejemplos. El estándar de calidad continúa existiendo: las etiquetas deben representar ese estándar con suficiente consistencia.

Incluso un sistema que contiene aprendizaje automático puede terminar con una regla. Un modelo podría estimar una dimensión a partir de una imagen y, después, una condición podría compararla con el límite permitido. **Hay que identificar qué hace cada etapa:** obtener una medición, estimar una magnitud, predecir una categoría y aplicar una especificación no son operaciones equivalentes.

13 Reglas aprendidas y sistemas combinados

Un árbol de decisión puede aprender condiciones

Imaginemos que una persona escribe: «si un mensaje tiene más de tres enlaces, marcarlo como spam». El número tres fue fijado manualmente y constituye una regla. Ahora imaginemos que entrenamos un árbol de decisión con mensajes etiquetados. El algoritmo puede seleccionar una condición sobre la cantidad de enlaces porque esa separación resulta útil en los datos de entrenamiento.

Los árboles de decisión aprenden reglas de separación a partir de características y objetivos conocidos. [5] La regla final puede verse muy parecida a una condición escrita a mano. Lo que permite distinguirlas es su procedencia: **una fue impuesta directamente; la otra fue seleccionada durante el entrenamiento.**

Esto muestra por qué decir «el aprendizaje automático no tiene reglas» resulta engañoso. Algunas relaciones aprendidas pueden expresarse como reglas claras. En otros modelos se representan mediante coeficientes, distancias u otras estructuras. No necesitamos que el modelo resulte misterioso para considerarlo aprendizaje automático.

Una probabilidad aprendida y un umbral elegido

Supongamos que un clasificador devuelve una probabilidad estimada de spam de 0,87. La organización decide enviar a revisión los correos cuya probabilidad sea igual o mayor que 0,80. El 0,87 proviene del modelo entrenado; el 0,80 es un umbral de decisión que se eligió para operar el sistema.

La comparación «0,87 es mayor o igual que 0,80» es una regla, pero no elimina la etapa de aprendizaje anterior. El sistema combina una estimación aprendida con una decisión programada. El umbral puede seleccionarse considerando los errores que se quieren evitar y los resultados de validación, sin utilizar el conjunto final de prueba para ajustarlo.

Si bajamos el umbral, más correos pueden ser tratados como spam; si lo subimos, menos correos alcanzarán la condición. Cambiar ese límite no equivale a volver a entrenar el modelo que produce las probabilidades. Son modificaciones distintas y conviene describirlas por separado.

Una aplicación puede tener varias partes

Etapa	Ejemplo	Tipo de procedimiento
Estimar	Predecir el consumo del mes con un modelo entrenado.	Regresión aprendida.
Calcular	Multiplicar el consumo estimado por una tarifa definida.	Regla de cálculo.
Decidir	Mostrar una alerta si el importe supera un límite elegido.	Regla de decisión.

Por eso es preferible decir «esta etapa utiliza aprendizaje automático» antes que atribuir aprendizaje a todas las operaciones de una aplicación. Una predicción, una multiplicación y una alerta pueden aparecer juntas y tener orígenes distintos.

14 Cómo analizar un caso sin confundirse

Preguntas que permiten justificar la respuesta

Primero, describí qué se quiere resolver y qué información está disponible en ese momento. «Calcular el sueldo» puede significar liquidar un importe pactado o estimar un salario de mercado. Si no aclaramos esa diferencia, la respuesta queda ambigua.

Después, buscá el origen de la relación entre entradas y salida. ¿Existe una fórmula o condición que se debe aplicar? ¿Se ajustó un modelo usando ejemplos? Si hubo entrenamiento, identificá las características, la variable objetivo y los datos utilizados. Si se usa un modelo ya entrenado por otra persona, también hay aprendizaje automático, aunque quien lo consulta no ejecute el entrenamiento.

Finalmente, identificá el significado de la salida. Si el modelo aprendido estima una magnitud, se trata de regresión en los casos que estamos estudiando. Si predice una clase, se trata de clasificación. Si el enunciado no explica cómo funciona el sistema, **no alcanza con conocer su salida para decidir si utiliza aprendizaje automático**.

Afirmación que confunde	Cómo corregirla
«Da un número, entonces es regresión».	Puede ser una cuenta programada. Hay que comprobar si hubo aprendizaje.
«Devuelve una clase, entonces usa aprendizaje automático».	Las reglas también asignan clases. Importa cómo se obtuvo el criterio.
«Tiene una fórmula, entonces no aprendió».	Una fórmula puede contener coeficientes ajustados con datos.
«Usa muchos datos, entonces aprende».	Consultar registros y ajustar un modelo son operaciones diferentes.
«Se equivoca, entonces es aprendizaje automático».	Las reglas pueden ser inadecuadas, y los modelos también pueden fallar.
«Se actualiza solo, entonces aprende».	Puede actualizar una tarifa por una regla. Hay que identificar qué se modifica y cómo.
«Aprendió una vez, entonces mejora con cada consulta».	La predicción no implica actualización del modelo.
«No conozco una regla, entonces el modelo podrá aprender».	Se necesitan datos informativos y una evaluación que demuestre utilidad.

Una justificación completa puede decir: «Es clasificación mediante aprendizaje automático porque el sistema se entrenó con consultas y sus categorías correctas; utiliza lo aprendido para asignar una categoría a una consulta nueva». Esa explicación identifica el entrenamiento, la respuesta buscada y el uso del modelo.

15 Actividades para practicar

Para cada caso, indicá si hay reglas preestablecidas, regresión de aprendizaje automático, clasificación de aprendizaje automático, una combinación o información insuficiente. Justificá tu respuesta por el origen del criterio. Cuando haya un modelo, identificá sus entradas y su variable objetivo.

Casos

- 1. Horas trabajadas.** Un programa recibe 160 horas y una tarifa pactada de \$5.000 por hora. Multiplica ambos valores para obtener el importe a pagar.
- 2. Salarios comparables.** Un sistema se entrena con perfiles laborales y salarios observados. Luego estima el salario mensual para un perfil nuevo.
- 3. Alquiler pactado.** Una planilla aplica un incremento fijo del 8 % al importe anterior, según las condiciones ficticias del ejercicio.
- 4. Alquiler anunciado.** Una aplicación recibe las características de una vivienda y devuelve \$700.000. El enunciado no indica cómo se obtuvo ese importe.
- 5. Promoción comercial.** Un negocio etiqueta como «cliente con descuento» a quien realizó más de cinco compras. Esa condición fue escrita por la gerencia.
- 6. Abandono de clientes.** Un modelo se entrena con uso del servicio y reclamos registrados antes del cierre de contratos. Aprende a predecir si un cliente cancelará durante el mes siguiente, usando resultados históricos conocidos.
- 7. Filtro de correo.** Si aparece «herencia», el programa envía el mensaje a spam. Cada vez que se detecta una nueva expresión, una persona la agrega a la lista.
- 8. Correo con clases numéricas.** Un modelo entrenado con correos etiquetados devuelve 0 para legítimo y 1 para spam.
- 9. Una fórmula guardada.** Una regresión se ajustó con alquileres anteriores. Luego se copiaron sus coeficientes a una aplicación que utiliza esa fórmula sin volver a entrenarla.
- 10. Un árbol con condiciones.** El entrenamiento de un árbol seleccionó reglas sobre el texto y los enlaces de correos etiquetados. El árbol utiliza esas reglas para clasificar mensajes nuevos.
- 11. Consumo y factura.** Un modelo entrenado estima los kWh del próximo mes. Después, el sistema multiplica la estimación por una tarifa conocida y emite una alerta si se supera un límite fijado.
- 12. Dos formas de analizar la aprobación.** El sistema A recibe la nota final y aplica el requisito de aprobar con 6 o más. El sistema B se entrena con datos disponibles a mitad de cursos anteriores y con los resultados finales para anticipar si alguien aprobará.

Pregunta para discutir

Dos programas muestran exactamente la misma fórmula y producen el mismo importe. En uno, una persona eligió los coeficientes. En el otro, los coeficientes se ajustaron con una regresión. ¿Qué información necesitás para explicar por qué el origen de la fórmula es diferente?

16 Respuestas fundamentadas

1. Reglas preestablecidas. Se aplica una multiplicación conocida: 160 por \$5.000 da \$800.000. Las horas y la tarifa son datos para ejecutar la regla. No hay entrenamiento ni una relación ajustada con ejemplos.

2. Regresión. El modelo utiliza perfiles como entradas y salarios observados como objetivo de entrenamiento. Después estima una magnitud monetaria para otro perfil. La justificación es el ajuste con datos, no el hecho de que el resultado sea dinero.

3. Reglas preestablecidas. La planilla aplica un porcentaje ya establecido. No necesita inferirlo ni aprender la relación a partir de alquileres anteriores. Un cálculo automático de un valor futuro puede seguir siendo un cálculo por reglas.

4. Información insuficiente. La salida numérica no revela el método. Podría provenir de una regla manual, un modelo entrenado, una consulta a una base o un importe ingresado por una persona. Hace falta conocer el procedimiento.

5. Reglas preestablecidas. La categoría depende de una condición escrita por la gerencia. Contar compras y comparar el total con cinco no implica aprendizaje, aunque el sistema use un historial de transacciones.

6. Clasificación. Las entradas incluyen uso y reclamos disponibles antes de la predicción. La variable objetivo indica si hubo cancelación en el período definido. El modelo aprende a distinguir esas clases con ejemplos históricos.

7. Reglas preestablecidas. La lista la modifica una persona. Incorporar nuevas palabras manualmente es mantener el filtro, no entrenar un modelo. La salida spam o legítimo, por sí sola, no demuestra aprendizaje.

8. Clasificación. Los números 0 y 1 son códigos de categorías. El modelo no está estimando una magnitud continua: utiliza relaciones aprendidas para decidir entre correo legítimo y spam.

9. Regresión en la etapa de predicción. Los coeficientes tienen origen en un entrenamiento. Copiarlos a otra aplicación y aplicar la fórmula no elimina ese origen. La aplicación está utilizando un modelo aprendido, aunque no lo actualice con cada consulta.

10. Clasificación. Las condiciones fueron seleccionadas durante el entrenamiento con correos etiquetados. Tener reglas visibles no convierte al árbol en una lista de reglas redactadas manualmente. Importa cómo se obtuvieron.

11. Combinación. La estimación de kWh es regresión aprendida. La multiplicación por la tarifa y la comparación con el límite son reglas. El importe proyectado hereda la incertidumbre de la estimación del consumo.

12. Dos procedimientos distintos. A aplica una regla a una nota conocida. B utiliza clasificación aprendida para anticipar un resultado desconocido con datos de mitad de curso. La predicción de B no determina la condición académica que debe registrar A.

Discusión. Necesitás conocer la procedencia de los coeficientes y si existió un procedimiento de ajuste con datos. La misma apariencia matemática no demuestra el mismo origen. En un caso la relación se fijó directamente; en el otro se obtuvo mediante entrenamiento.

17 Repaso y lecturas de apoyo

Cuatro casos que conviene recordar

Situación	Qué se hace	Cómo se reconoce
Liquidar un sueldo	Aplicar importes, condiciones y operaciones conocidos.	Cálculo con reglas.
Estimar un salario	Ajustar un modelo con perfiles y salarios observados.	Regresión aprendida.
Filtrar palabras prohibidas	Aplicar una lista escrita por una persona.	Clasificación por reglas.
Detectar spam con ejemplos	Entrenar con correos y sus etiquetas para clasificar otros.	Clasificación aprendida.

Vocabulario de este apunte

Regla preestablecida: condición o relación que una persona fija para que el programa la aplique.

Entrenamiento: proceso que obtiene o ajusta un modelo usando datos. **Modelo:** representación de la relación aprendida que se utiliza para resolver nuevos casos.

Características: información de entrada. **Variable objetivo:** respuesta que se quiere predecir.

Inferencia: aplicación del modelo ya entrenado. **Generalización:** capacidad de resolver adecuadamente casos que no se usaron para ajustar el modelo.

La pregunta más útil ante un sistema es **cómo se obtuvo la relación que produce su respuesta**. Después de establecer si existe aprendizaje, podemos distinguir si el objetivo es estimar una magnitud o predecir una clase. Ese orden evita confundir una cuenta con una regresión y una condición con un clasificador entrenado.

Fuentes para ampliar los conceptos

Los ejemplos, importes, actividades y explicaciones aplicadas de este apunte son de elaboración didáctica. Las siguientes fuentes oficiales amplían los conceptos señalados con números en el texto. Los títulos incluyen enlaces a las páginas consultadas.

[1] [Google for Developers — Aprendizaje supervisado](#)

[2] [Google for Developers — Qué es el aprendizaje automático](#)

[3] [scikit-learn — Extracción de características de texto y n-gramas](#)

[4] [Google for Developers — Entrenamiento estático y dinámico](#)

[5] [scikit-learn — Árboles de decisión](#)