

Dataset para un Estudio Estadístico:	Dataset para Entrenar un Modelo de Machine Learning:
• Propósito Principal: Describir, resumir, analizar relaciones y extraer inferencias sobre una población basándose en una muestra de datos. El objetivo es comprender las características de los datos y probar hipótesis. • Estructura y Contenido: ◦ Variables: Son las características que se miden u observan. Pueden ser de diferentes tipos (numéricas, categóricas, ordinales, etc.). ◦ Unidades de Observación: Cada fila representa una unidad sobre la cual se recopilan las variables (por ejemplo, una persona, un objeto, un evento). ◦ Muestreo: La forma en que se recolectan los datos es fundamental para asegurar que la muestra sea representativa de la población de interés y permitir inferencias válidas. Se presta mucha atención a las técnicas de muestreo (aleatorio simple, estratificado, etc.). ◦ Tamaño de la Muestra: El tamaño de la muestra debe ser suficiente para tener poder estadístico para detectar efectos significativos si existen. ◦ Calidad de los Datos: Al igual que en machine learning, la precisión y la limpieza de los datos son importantes para obtener resultados confiables. ◦ Consideraciones Estadísticas: El diseño del estudio (observacional, experimental), la independencia de las observaciones y la distribución de las variables son consideraciones cruciales para la elección de las pruebas estadísticas apropiadas. ◦ No necesariamente una variable objetivo: Si bien puede haber una variable dependiente e independiente en estudios de regresión o comparación de grupos, el objetivo principal no siempre es la predicción. A menudo se centra en la comprensión de las relaciones y la significancia estadística. ◦ Puede no requerir particiones: Si el objetivo es principalmente descriptivo o inferencial, no siempre es necesario dividir el dataset en conjuntos de entrenamiento, validación y prueba como en machine learning.	• Propósito Principal: Enseñar a un algoritmo a reconocer patrones, realizar predicciones o tomar decisiones sin ser explícitamente programado para cada tarea. El objetivo es que el modelo aprenda a generalizar a partir de los datos de entrenamiento para aplicarse a datos nuevos e unseen. • Estructura y Contenido: ◦ Características (Features): Son las variables de entrada que el modelo utiliza para aprender. Idealmente, deben ser relevantes para la tarea y estar bien representadas. ◦ Variable Objetivo (Target/Label): En el aprendizaje supervisado, este es el valor que el modelo debe aprender a predecir. Puede ser una categoría (clasificación) o un valor numérico (regresión). ◦ Suficiente Cantidad de Datos: Los modelos de machine learning, especialmente los complejos como las redes neuronales, a menudo requieren grandes cantidades de datos para aprender patrones robustos y evitar el sobreajuste (overfitting). ◦ Diversidad y Representatividad: El dataset debe cubrir una amplia gama de posibles escenarios para que el modelo funcione bien en datos nuevos. Debe ser representativo de la población o el problema que se está modelando para evitar sesgos. ◦ Calidad de los Datos: Es crucial que los datos sean precisos, consistentes y estén limpios (manejo de valores faltantes, eliminación de ruido y outliers, etc.). ◦ Balance de Clases (en clasificación): Si la tarea es clasificar objetos en diferentes categorías, es importante que el número de ejemplos en cada categoría esté razonablemente equilibrado para evitar que el modelo favorezca la clase mayoritaria. ◦ Particiones: El dataset se suele dividir en al menos tres partes: ■ Conjunto de Entrenamiento (Training Set): Utilizado para entrenar el modelo. ■ Conjunto de Validación (Validation Set): Utilizado para ajustar los hiperparámetros del modelo y evaluar su rendimiento durante el entrenamiento para evitar el sobreajuste. ■ Conjunto de Prueba (Test Set): Utilizado para evaluar el rendimiento final del modelo entrenado en datos completamente nuevos. Este conjunto no se utiliza durante el entrenamiento ni la validación.