

Aprendizaje Automático - Libro 1 - Clase 1 a 7

1. Clase 1

Clase N° 1: Conceptos previos y herramientas

Contenido: Introducción. Técnicas de Aprendizaje Automático. Concepto de Aprendizaje Supervisado y No Supervisado. Definición y flujo de un proceso de Machine Learning. Herramientas.

En la clase de hoy trabajaremos los siguientes temas:

- Introducción
- Uso actual en la gestión del conocimiento empresarial
- Técnicas de Aprendizaje Automático
- Núcleo del aprendizaje automático
- Flujo de trabajo
- Los 6 Roles del equipo IA
- Las Habilidades de un buen colaborador ML
- Herramientas

1. Presentación:


Bienvenidos a la clase N° 1 de Aprendizaje Automático.

En esta clase, estaremos abordando el tema de "Conceptos previos y herramientas". Esta etapa inicial es fundamental ya que nos brindará las bases necesarias para sumergirnos de lleno en el fascinante mundo de esta disciplina.


Los conceptos y herramientas que exploraremos desempeñan un papel crucial al introducirnos en la materia. Este tema ha sido diseñado para sentar las bases sólidas que nos permitirán comprender de manera más profunda y significativa las técnicas y algoritmos de Aprendizaje Automático que exploraremos en detalle en el futuro.

Con esta sólida base, estaremos preparados para adentrarnos en las complejidades de los diversos enfoques y métodos del Aprendizaje Automático. La comprensión de estos conceptos previos y la familiarización con las herramientas pertinentes nos brindarán una ventaja invaluable a medida que profundicemos en nuestro viaje de aprendizaje.

¡Estoy emocionado por acompañarte en esta maravillosa aventura de Aprendizaje Automático y explorar juntos los conceptos fundamentales que nos abrirán las puertas a un mundo de posibilidades!



Te invitamos ahora a ver el video [Qué es aprendizaje automático o machine learning](#) para introducirnos en el tema.



2. Desarrollo y Actividades:

Introducción

El aprendizaje realizado por las máquinas no puede sustituir actualmente el conocimiento aplicado que pueden desarrollar un grupo de expertos dentro de una determinada área, pero puede potenciar los logros alcanzados, por ejemplo permitiendo:

- Procesar volúmenes de datos inmanejables por una persona.
- Encontrar patrones dentro de los datos.
- Tomar decisiones en fracciones de segundos.

Las máquinas pueden tornarse de esta forma en una herramienta que nos puede incluso ayudar a salvar vidas en áreas muy diversas, como pueden ser por ejemplo:

- La **salud** al utilizar robots que permitan a un cirujano prever situaciones en medio de una operación.
- El **ordenamiento vial** al poner en circulación autos inteligentes que puedan prevenir un accidente en el caso de que una persona se duerma o sufra un ataque cardíaco perdiendo de esta forma el control del auto.

Las áreas de aplicación son muchas, desde fines altruistas a fines bélicos, pero todas tienen detrás la misma metodología, utilizando modelos de aprendizaje automático basados en estadísticas, teoría de probabilidad, álgebra lineal y la optimización continua del modelo mediante construcciones matemáticas.

Realizar todo desde cero en cada trabajo sería una tarea muy ardua, afortunadamente hoy en día con la ayuda de PYTHON contamos con una gran cantidad de herramientas que realizan parte del trabajo por nosotros.

Uso actual en la gestión del conocimiento empresarial

En la gestión del conocimiento empresarial, el Aprendizaje Automático (Machine Learning) juega un papel crucial al permitir a las organizaciones aprovechar sus datos para tomar decisiones más informadas y eficientes. Aquí hay algunas formas en las que se utiliza el Aprendizaje Automático en la gestión del conocimiento empresarial:

Análisis de Datos: Las empresas pueden utilizar algoritmos de Aprendizaje Automático para analizar grandes cantidades de datos y extraer patrones, tendencias y relaciones ocultas. Esto ayuda a identificar información valiosa que puede influir en la toma de decisiones estratégicas.

Personalización: El Aprendizaje Automático se utiliza para personalizar la experiencia del cliente y la oferta de productos. Los sistemas pueden analizar los comportamientos pasados y las preferencias de los clientes para ofrecer recomendaciones y sugerencias específicas.

Optimización de Operaciones: Las empresas pueden utilizar modelos de Aprendizaje Automático para optimizar sus operaciones internas, como la gestión de inventario, la planificación de la cadena de suministro y la programación de la fuerza laboral.

Detección de Fraudes: En sectores como la banca y los servicios financieros, el Aprendizaje Automático se utiliza para detectar patrones de actividad sospechosa y prevenir fraudes.

Procesamiento del Lenguaje Natural (NLP): Las técnicas de NLP basadas en Aprendizaje Automático permiten a las empresas extraer información útil de grandes volúmenes de texto, como correos electrónicos, informes y comentarios de clientes.

Optimización de Marketing: El Aprendizaje Automático ayuda a las empresas a comprender mejor a su audiencia y a segmentarla para campañas de marketing más efectivas. También puede utilizarse para predecir tendencias de mercado y comportamientos de los consumidores.

Mantenimiento Predictivo: En sectores industriales, el Aprendizaje Automático se utiliza para predecir fallos en equipos y maquinaria, permitiendo un mantenimiento preventivo más eficiente.

Automatización de Procesos: Los algoritmos de Aprendizaje Automático pueden automatizar tareas repetitivas y procesos empresariales, liberando tiempo para tareas más estratégicas y creativas.

Toma de Decisiones: Los modelos de Aprendizaje Automático pueden proporcionar información basada en datos para respaldar la toma de decisiones, ayudando a reducir la incertidumbre y mejorar la precisión.

Técnicas de Aprendizaje Automático

Todo modelo debe contar con una entrada de datos, los cuales pueden ser de diferente tipo, como datos de texto, números, imágenes e incluso audio o video. Y contar con una salida que represente por ejemplo la variación de una temperatura dada por un valor flotante o la asignación de un valor asociado al reconocimiento de una imagen que pueda retornar las huellas digitales de una persona con determinadas características biométricas.

El objetivo principal del aprendizaje automático es analizar y construir algoritmos que puedan en base a datos históricos, aprender y realizar predicciones sobre nuevos datos de entrada y que sean capaces de definir que tan bien el modelo realizado está aprendiendo.

En base al tipo de datos de entrada podríamos realizar una clasificación del tipo de tarea de aprendizaje en:

Aprendizaje Supervisado: En este enfoque, el algoritmo se entrena utilizando un conjunto de datos etiquetado, es decir, datos en los que las respuestas correctas ya están proporcionadas. El objetivo es que el algoritmo aprenda a hacer predicciones precisas en nuevos datos no vistos. por ejemplo, crear una plataforma para realizar encuestas que clasifican los datos y preferencias de las personas de forma tal de poder encontrar patrones que permitan generar una regla que asigne a una determinada preferencia una salida específica. En este caso se pueden utilizar técnicas que incluyen Algoritmos de Regresión Lineal, Máquinas de Vectores de Soporte (SVM), y Árboles de Decisión.

Otros algoritmos que son utilizados en esta técnica son: k-Nearest Neighbors, Logistic Regression, Bayesian Classifiers, Decision Tress and Random Forest, Neural Networks, Deep Learning.

Aprendizaje No Supervisado: Aquí, el algoritmo se enfrenta a datos sin etiquetas y busca patrones y estructuras inherentemente presentes en los datos. Los algoritmos de clustering (agrupamiento) son ejemplos de técnicas no supervisadas, como el K-Means, Principal Component Analysis (PCA), Anomaly Detection y el Clustering Jerárquico. Utilizado para detectar por ejemplo patrones de comportamiento en base a datos que no traen asociados una descripción adjunta.

Estas serán las técnicas que veremos en la cursada. No significa que sean las únicas. Estas son solo algunas de las muchas técnicas y enfoques dentro del Aprendizaje Automático. hay otros como: Aprendizaje por Refuerzo, Aprendizaje Profundo (Deep Learning), Aprendizaje Semi-Supervisado y Aprendizaje Activo, Reducción de Dimensionalidad, Regularización, Ensemble Learning, Aprendizaje Transferido, etc. Cada técnica tiene sus propias ventajas y desafíos, y la elección de la técnica adecuada depende de la naturaleza del problema que estás tratando de resolver.

Núcleo del aprendizaje automático

Lo bueno de los datos es que hay muchos en el mundo. Lo malo es que es difícil procesar estos datos. Los desafíos provienen de la diversidad y el ruido de los datos. Nosotros, los humanos, usualmente procesamos datos que llegan a nuestros oídos y ojos. Estas entradas se transforman en señales eléctricas o químicas. En un nivel muy básico, las computadoras y los robots también funcionan con señales eléctricas. Estas señales eléctricas se traducen entonces en unos y ceros. Sin embargo, nosotros vamos a programar en Python y normalmente representamos los datos como números, imágenes o textos. En realidad, las imágenes y el texto no son muy convenientes, por lo que necesitamos transformar las imágenes y el texto en valores numéricos.

Especialmente en el contexto del aprendizaje supervisado, tenemos un escenario similar al de estudiar para un examen. Tenemos un conjunto de preguntas de práctica y los exámenes reales. Deberíamos poder responder las preguntas del examen sin saber las respuestas a ellas. Esto se llama **generalización**, aprendemos algo de nuestras preguntas de práctica y, con suerte, podemos aplicar el conocimiento a otras preguntas similares. En el aprendizaje automático, estas preguntas de práctica se denominan **conjuntos de entrenamiento o muestras de entrenamiento**. Son de donde los modelos derivan patrones. Y los exámenes reales son conjuntos de

prueba o muestras de prueba. Son donde se aplican los modelos y se extrae cuán compatibles son. A veces, entre las preguntas de práctica y los exámenes reales, tenemos exámenes simulados para evaluar qué tan bien vamos a hacer en los reales y para ayudar a la revisión. Estos exámenes simulados se denominan **conjuntos de validación** o **muestras de validación** en aprendizaje automático. Nos ayudan a verificar qué tan bien se comportan los modelos en una configuración simulada, luego ajustamos los modelos en consecuencia para lograr mayores éxitos.

Flujo de trabajo

La creación de aplicaciones de aprendizaje automático, aunque es similar en muchos aspectos al paradigma de la ingeniería estándar, difiere en un aspecto crucial: *la necesidad de trabajar con datos como materia prima*. El éxito de un proyecto dependerá, en gran parte, de la calidad de los datos que se adquiera, así como del manejo de dichos datos. Y cómo trabajar con datos cae en el dominio de la *ciencia de datos*, es útil comprender el flujo de trabajo de la ciencia de datos, el cual está compuesto por cinco pasos:

1. Hacer una pregunta interesante
2. Obtener los datos
3. Explorar y preparar los datos
4. Modelar y analizar los datos
5. Comunicar y Visualizar los resultados

Realicemos un pequeño comentario sobre cada punto vinculándolo con el Aprendizaje Automático (Machine Learning):

Hacer una pregunta interesante

Para que una pregunta de interés, la cual hallará respuesta a través de los datos, sea planteada de manera efectiva, es necesario llevar a cabo un exhaustivo análisis del contexto empresarial o del emprendimiento que es el foco de nuestra atención. En esta etapa inicial de Análisis de Negocio, se identifican minuciosamente las fuentes de datos ya disponibles o aquellas que pueden ser desarrolladas para nutrir con precisión los futuros modelos de aprendizaje automático. Mediante este estudio, los cimientos necesarios son proporcionados para la posterior toma de decisiones y el diseño de estrategias.

En simultáneo, durante esta fase, los objetivos que se aspira alcanzar mediante la integración de la Inteligencia Artificial en el proyecto son delineados. Además, las métricas son formuladas o sugeridas, las cuales servirán como criterios para evaluar si los resultados obtenidos efectivamente aportarán valor al negocio, o si, por el contrario, es más conveniente reevaluar el enfoque.

Esta etapa, que representa el punto de partida del ciclo de vida del proyecto, juega un rol crítico. Las decisiones tomadas aquí influirán en las etapas subsiguientes y orientarán la dirección del proyecto en su totalidad. En sucesivas iteraciones del ciclo de vida, será esta fase la que determinará si el proyecto debe continuar o si es más apropiado dar por finalizada la iniciativa. La utilización de visualizaciones detalladas y reportes (o paneles) desempeñará un papel crucial en la comprensión del comportamiento de los modelos y en la obtención de una perspectiva clara sobre su desempeño.

Obtener los datos

Los datos para aplicaciones de aprendizaje automático pueden provenir de varios tipos de fuentes, como un correo electrónico, una encuesta online, un captcha o un sin número de opciones más, y en varios formatos, que pueden ser números, texto, imágenes, audio, etc. Independientemente de la fuente y del formato es crucial comprender bien cuál es el contenido de los datos.

Explorar y preparar los datos

Una vez adquiridos los datos, el siguiente paso es inspeccionarlos. El objetivo principal en esta etapa es verificar la integridad de los datos, y la mejor manera de lograrlo es buscar cosas que sean imposibles o muy poco probables. Como ejemplo, si los datos tienen un identificador único, verifique que exista uno solo; si los datos se basan en el precio, verifique que siempre sea positivo; y cualquiera que sea el tipo de datos, verifique los casos más extremos. Es una buena práctica realizar estadísticas simples en los datos y visualizarlos. Este paso tiene un impacto directo sobre la eficacia del modelo a realizar.

Luego de inspeccionar los datos, debemos estar seguros de que se encuentran ordenados de forma de colocar en un formato que resulte fácil de modelar. En esta etapa es imprescindible comprender bien cuál es el tipo de datos con el cual estamos trabajando, así como las bibliotecas y algoritmos a utilizar.

Modelar y analizar los datos

Una vez que se completa la preparación de los datos, la siguiente fase es el modelado. Aquí, seleccionaremos un algoritmo apropiado y utilizaremos los datos para entrenar un modelo. En esta etapa debemos evaluar cómo responde el modelo, la forma de evaluación depende en gran medida del tipo de datos que estamos utilizando y del tipo de modelo seleccionado, pero en líneas generales estamos buscando conocer que tan bien responde a las predicciones realizadas.

Comunicar y Visualizar los resultados

Al final nos resta implementar el modelo en la práctica, el cual puede ubicarse dentro de una aplicación ya creada, una página web u otro tipo de forma de obtener datos del medio.

Los 6 Roles del equipo IA

A continuación, se hará mención de los 6 roles que abarcan las distintas etapas del ciclo de vida de los proyectos de IA. En muchas ocasiones, estos roles se superponen entre sí y es común observar cómo es posible identificarse con más de uno de ellos. La estructuración de estos roles tiene como propósito lograr la especialización en cada uno de ellos y la obtención de los beneficios, especialmente en una gran compañía, que son proporcionados por la suposición de la separación de tareas.

1. Data Scientist
2. Machine Learning Engineer
3. Data Analyst
4. Software Engineer ML
5. ML Researcher
6. Software Engineer

Skills de un Data Scientist

El científico de datos puede desarrollar las etapas de Ingeniería de Datos, modelado y Análisis de Negocio. Deberá tener fundamentos científicos sólidos así como habilidades en comunicación para poder transmitir los hallazgos a otros miembros del equipo ó a usuarios de negocio.

TOOLS: Python, numpy, scikit learn, Tensorflow, Pytorch, SQL, Tableau, Excel, PowerBI, Git, Jupyter Notebook.

Skills de un Machine Learning Engineer

Pueden desarrollar las tareas de Ingeniería en datos, modelado y despliegue. En algunos casos también pueden colaborar con la analíticas de negocio y en la infraestructura.

Deben tener habilidades en ingeniería pero también ciencias. Sus competencias en comunicación pueden depender de las necesidades del equipo y del resto de roles. Se prevé que este rol esté al tanto de las últimas tendencias en algoritmos y papers relacionados con Machine Learning y el uso y técnicas de Deep Learning.

TOOLS: Python, SQL, numpy, scikit learn, Tensorflow, Pytorch, Cloud: AWS, Azure, GCP, Git, Jupyter Notebook, JIRA.

Skills de un Data Analyst

Preparado para las fases de Ingeniería de Datos y Análisis de Negocios. Por lo general tienen un gran conocimiento de SQL y manejo de bases de datos y analítica avanzada de negocios, visualización y reporting.

Por lo general se pretende de este rol muy buenas habilidades comunicativas, y se les exige menos en capacidad algorítmica ó de programación.

TOOLS: Python, SQL, Tableau, PowerBI, Excel, PowerPoint, A/B testing.

Skills de un Software Engineer en Machine Learning

Personas con este título podrán desarrollar las etapas de Ingeniería de Datos, modelado, despliegue e infraestructura.

Deberían trabajar bien con otros miembros que trabajen con la parte de negocio. Este rol es conveniente para etapas tempranas de equipos o startups pues puede cubrir multitud de tareas, logrando prototipos y demostrando gran versatilidad.

TOOLS: Python, SQL, numpy, scikit learn, Tensorflow, Pytorch, AWS, GCP, Azure, Git, Jupyter Notebook, JIRA.

Skills de un Machine Learning Researcher

Este rol puede llevar las etapas de Ingeniería de datos y modelado. Desarrollan su mayor potencial en un ambiente de investigación, donde puedan dar rienda a sus conocimientos para buscar y descubrir patrones en los datos. Debe tener excelentes habilidades y conocimiento científico.

También puede especializarse en Deep Learning ó en algun área en particular como NLP, visión artificial ó motores de recomendación.

TOOLS: Python, SQL, numpy, scikit learn, Tensorflow, Pytorch, Git, Jupyter Notebook, Arxiv, NeurIPS, papers.

Skills de un Software Engineer

Este rol -ahora muy ligado a "devops"- puede ocuparse de las etapas de Ingeniería de Datos e Infraestructura.

Demuestran gran habilidad en programación y manejo de software y diversas herramientas o plataformas especializadas.

TOOLS: Python, SQL, AWS, GCP, Azure, Git, Jupyter Notebook, JIRA.

Las Habilidades de un buen colaborador ML

Se procederá a enumerar algunas de las habilidades y herramientas más frecuentemente requeridas al solicitar los servicios de estos profesionales capacitados.

Machine Learning:

- PCA
- Knn
- K-means
- SVM
- Regresión Logística / Lineal
- Árbol de Decisión

Deep Learning

- Fully Connected
- Convolutional NN
- Recurrent NN
- Transfer Learning

Data Science

- Probabilidad (Bayes, condicional)
- Estadística (hipótesis, bias/varianza)
- Análisis de Datos (Visualización, métricas)

Matemáticas

- Álgebra lineal (vectores, matrices)
- Cálculo (derivadas, integrales)
- Funciones matemáticas (min, max)

Algorithmic Coding

- Programación de algoritmos
- Estructuras de datos
- Ordenamiento y búsqueda

Software Engineering

- Manejo de Software científico
- Programación Orientada a Objetos
- Rest Apis
- Base de Datos / Sql y NoSql
- Repositorios (git), TDD

Herramientas

Anaconda

Anaconda es para nosotros, una herramienta indispensable, ya que nos va a permitir trabajar no solo con python, sino que además podremos interactuar con programas realizados en R, Julia y Octave. Estos lenguajes son un complemento indispensable al profundizar en el tema que nos ocupa.

- R es un lenguaje de programación para computación estadística y gráficos.
- Julia es utilizado en computación numérica y está diseñada para programar en la nube.
- Octave es para computación numérica y trabajos matemáticos.

Para mayor información podemos acceder a <https://www.anaconda.com/>

Jupyter

Jupyter es una de las herramientas más útiles en el análisis de datos con python la cual viene dentro de las aplicaciones que instalamos junto con Anaconda. Cuando utilizamos jupyter, podemos cargar datos, transformarlos y modelarlos dentro de una única ventana, permitiendo probar el código y explorar ideas de forma rápida y fácil. Sumado a esto Jupyter nos permite documentar el código, agregando texto con formato de forma de incluso poder generar un reporte de lo realizado.

Básicamente Jupyter permite crear ventanas web que se ejecutan localmente y contienen código que puede ser editado en el momento tanto en python como en R.

Las notebook Jupyter son aplicaciones web que se ejecutan localmente y contienen códigos en vivo, ecuaciones, figuras, aplicaciones interactivas y texto de Markdown. El lenguaje estándar es Python, y es el lenguaje que usaremos en la cursada; sin embargo, debemos tener en cuenta que una variedad de alternativas son compatibles. Esto incluye el otro lenguaje de ciencia de datos dominante, R.

En el sitio del proyecto se puede encontrar más información <https://jupyter.org/>

NumPy

NumPy es una de las piedras fundamentales que posee python en el área de análisis numérico que suele ser utilizado por matemáticos, científicos e ingenieros, así como por diversas plataformas en el área de inteligencia artificial y machine learning. NumPy permite trabajar con vectores y matrices de forma eficiente. Los vectores y matrices no son comparables a las listas de python aún cuando así lo parezca a simple vista.

Aunque las listas de Python son muy fáciles de crear y manipular, no admiten operaciones vectorizadas, a diferencia de las matrices creadas con esta herramienta. NumPy no solo es más eficiente en operaciones de matrices multidimensionales en comparación con las listas de Python, sino que también proporciona muchos métodos matemáticos que pueden ser utilizados con solo importar la librería.

Para obtener documentación e información sobre esta librería se puede acceder a <https://numpy.org/>

Pandas

Pandas es una librería de python que nos permite obtener datos de distinta procedencia como html, csv, json, pickle, sql. En el transcurso de las unidades iremos viendo cómo implementar Pandas.

En el sitio web <https://pandas.pydata.org/> se puede conseguir mas información al respecto.

Matplotlib

Matplotlib es un paquete de Python para la visualización de datos, que nos permite trabajar con diferentes formatos de representación. Matplotlib nos brinda una interfaz simple orientada a objetos en la cual podemos trazar desde gráficos simples a una amplia variedad de gráficos e incluso aplicarlo en el desarrollo web.

En <https://matplotlib.org/> podrás obtener ejemplos y documentación de este paquete.

Scikit-learn

Finalmente, scikit-learn es un software gratuito y de código abierto que nos ayuda en el trabajo del aprendizaje automático, está construido completamente en Python y utiliza las librerías de NumPy y SciPy. Scikit se ha vuelto muy popular, ya que permite implementar con bastante rapidez la mayoría de los algoritmos utilizados en la cursada.

Se puede obtener mas información accediendo a <https://scikit-learn.org/>

Actividad

Es importante que realices todas las actividades, estas te permitirán saber como vas avanzando y podrás reflexionar sobre la teoría si te queda alguna duda de cómo hacer esta actividad por favor consultanos en el campus.

1. Realizaremos la instalación de las herramientas necesarias para realizar los ejercicios. Puedes encontrar un paso a paso en la página <https://docs.anaconda.com/free/anaconda/install/>
2. Ahora vamos a hacer un recorrido por la interfaz de usuario de Jupyter. Podes acceder a la página <https://jupyter-notebook.readthedocs.io/en/stable/notebook.html>
3. Además, en esta primera semana deberás ir creando tu repositorio GITHUB para compartir las notebooks jupyter que iremos generando las próximas semanas.

3. INSTANCIA DE EVALUACIÓN - REGISTRO DE INTERCAMBIO - Participación en Foro Obligatorio

Criterios de evaluación:

- Entregar en tiempo y forma
- Realizar un 60% de la actividad correctamente.
- Cumplir con las consignas
- Cumplir con el formato requerido.

En esta instancia de autoevaluación deberás participar en el foro subiendo las actividades propuestas en la clase y cualquier otra apreciación de los contenidos vistos que te parezca relevante.

Recuerda leer la colaboración de tus compañeros y evita dar respuestas que ya han sido elaboradas por ellos. Si es posible intervení en las respuestas de tus compañeros.

Elegí uno de los ejemplos de Uso actual del aprendizaje automático en la gestión del conocimiento empresarial y compartí casos reales de aplicación en alguna organización o empresa.

4. Cierre:

En la actualidad, el Aprendizaje Automático se ha consolidado como una piedra angular en la gestión del conocimiento empresarial. Desde una introducción a sus conceptos fundamentales hasta un análisis de las habilidades requeridas y las herramientas más utilizadas en este campo, hemos explorado una amplia gama de temas. Desde el núcleo mismo del aprendizaje automático hasta las fases de flujo de trabajo y los roles críticos en un equipo de IA, hemos desglosado los aspectos clave de esta disciplina en constante evolución.

Ahora, es el momento de reflexionar y discutir en profundidad cómo estos conceptos se entrelazan en el panorama empresarial actual. ¿Cómo se refleja el uso del aprendizaje automático en la gestión del conocimiento empresarial? ¿Qué técnicas de aprendizaje automático demuestran ser más efectivas en diferentes contextos? ¿Qué desafíos y oportunidades identificamos al explorar los roles fundamentales en un equipo de IA? ¿Cómo se complementan las habilidades de un colaborador exitoso en Aprendizaje Automático con las herramientas disponibles?

Los invito a aportar sus perspectivas y análisis sobre estos temas en el foro. Ya sea desde la intersección entre la teoría y la práctica, la aplicación concreta en proyectos empresariales o las implicaciones éticas y sociales que conlleva, esta discusión nos brinda la oportunidad de profundizar en la importancia y el impacto del Aprendizaje Automático en el mundo actual.

Te espero en los próximos encuentros. Recordá que es importante participar de los foros, de los encuentros sincrónicos y en lo posible de las tutorías presenciales.

Para finalizar te dejamos estos recursos que pueden ayudarte a entender el tema un poco más.

Sitios

- NumPy.org, <http://www.numpy.org/>. Obtenido 11 Agosto 2023.
- Requests: HTTP para Humanos — documentación de Requests - 1.1.0, <http://es.python-requests.org/es/latest/>. Obtenido 11 Agosto 2023.
- Jupyter and the future of IPython — IPython, <http://ipython.org/>. Obtenido 11 Agosto 2023.
- pandas - Python Data Analysis Library, <https://pandas.pydata.org/>. Obtenido 11 Agosto 2023.
- Matplotlib — Visualization with Python, <https://matplotlib.org/>. Obtenido 11 Agosto 2023.
- seaborn: statistical data visualization — seaborn 0.12.2 documentation, <https://seaborn.pydata.org/>. Obtenido 11 Agosto 2023.
- scikit-learn: machine learning in Python — scikit-learn 1.3.0 documentation, <https://scikit-learn.org/stable/>. Obtenido 11 Agosto 2023.
- "Introduction to TensorFlow." TensorFlow, <https://www.tensorflow.org/learn>. Obtenido 11 Agosto 2023.
- "Installation — Anaconda documentation." Anaconda documentation, <https://docs.anaconda.com/free/anaconda/install/>. Obtenido 11 Agosto 2023.

5. Bibliografía Obligatoria:

- RUSSELL, R. (2018): Machine Learning. Guía Paso a Paso Para Implementar Algoritmos De Machine Learning Con Python
- CANE, A. (2019): Programación Con Python. Guía completa para principiantes.
- HAN, R. (2019): Matemáticas del Aprendizaje Automático. Introducción a la analítica de datos e Inteligencia Artificial.
- Mark Lutz, O'Reilly (2013, 02). Programming Python 5th Edition By
- Yuxi (Hayden) Liu, (2019, 02). Python Machine Learning By Example, Second Edition
- Alexander Combs, Michael Roman, (2019, 02). Python Machine Learning Blueprints, Second Edition